

## **Ante-anteproyecto TFG Hugo Silvosa**

### **Breve Resumen**

La traducción automática del chino al inglés ha logrado grandes avances con los modelos neuronales de Deep Learning, especialmente en dominios generales. Sin embargo, existen ciertos desafíos al aplicar estos sistemas a géneros literarios específicos, sobre todo cuando existen referencias culturales específicas. En concreto, las novelas de artes marciales chinas o “wuxia” presentan terminología y contextos profundamente arraigados en la cultura e historia antigua y folclórica de China, así como elementos fantásticos relacionados normalmente con la mitología china (títulos honoríficos, estilos de combate, rituales, conceptos de cultivación, etc.), lo que dificulta su traducción y evaluación mediante modelos genéricos de traducción automática. Como resultado de estas limitaciones, muchas de las traducciones actuales disponibles para novelas wuxia sufren de una falta de coherencia en los términos específicos y posibles errores en matices culturales, lo que afecta a la calidad y legibilidad del texto traducido.

Es por estas razones que la adaptación al dominio ha demostrado ser una vía útil y efectiva para mejorar los resultados de traducción. Al mismo tiempo, los modelos de lenguaje de última generación ya presentan un nivel notable de competencia en tareas de traducción general, por lo que este trabajo busca estudiar en qué medida su especialización con datos específicos del dominio puede mejorar el tratamiento de contenidos literarios, consiguiendo así una comparación entre dos enfoques distintos: modelos diseñados específicamente para traducir frente a modelos generalistas adaptados a una tarea concreta.

Este proyecto se centra en el desarrollo de un sistema de traducción automática adaptado al dominio wuxia para el par de idiomas chino–inglés. Para ello, se construirá un corpus paralelo alineando manualmente textos originales en chino con sus traducciones al inglés, a partir de novelas wuxia representativas (por ejemplo, Daoist Gu o la trilogía de los Cóndores de Jin Yong). Con este conjunto de datos especializado, se entrenarán y ajustarán modelos de traducción neuronal basados en arquitecturas Transformer. Estos actuarán como sistemas base (baseline), cuyo rendimiento se evaluará tanto cuantitativamente como cualitativamente sobre textos del dominio específico. Posteriormente, se llevará a cabo el fine-tuning de un modelo de lenguaje de gran tamaño (LLM), con el objetivo de analizar si estos modelos generalistas, tras aplicar fine-tuning, pueden igualar o superar a los NMT especializados en aspectos como la fluidez, la coherencia narrativa o la sensibilidad estilística del texto.

La efectividad de las traducciones se evaluará con métricas automatizadas estándar y avanzadas. Se considerarán métricas como BLEU, COMET, u otras similares, teniendo en cuenta sus respectivas limitaciones, especialmente en contextos literarios donde las variaciones estilísticas pueden influir en los resultados.

Finalmente, se llevará a cabo una comparación entre los distintos enfoques implementados, que incluirá tanto un análisis cuantitativo, basado en las métricas mencionadas, como un análisis cualitativo a partir de ejemplos de traducción seleccionados. Este último contemplará una evaluación humana que permita identificar en qué la adaptación al dominio mejora la calidad de las traducciones, así como las fortalezas y debilidades de cada solución.

## Objetivos concretos:

1. **Construcción de un corpus paralelo especializado:** compilar y alinear manualmente un conjunto de datos chino–inglés de novelas wuxia, garantizando la calidad de la traducción de referencia y su adecuación al dominio (terminología y estilo narrativo propios). Este corpus servirá como base para entrenar y evaluar los modelos.
2. **Entrenamiento de modelos de traducción neuronales base:** adaptar al dominio wuxia varios modelos de traducción automática basados en transformadores. Se considerarán modelos como MarianMT (modelo bilingüe de código abierto), mBART (modelo multilingüe preentrenado para traducción) y T5 multilingüe, entre otros. Mediante fine-tuning, cada modelo se entrenará con el corpus especializado para obtener sistemas de traducción enfocados en este tipo de texto.
3. **Evaluación con métricas adecuadas:** aplicar métricas automáticas para medir el rendimiento de las traducciones. Se utilizará BLEU para disponer de un punto de comparación con trabajos previos, examinando sus posibles deficiencias en traducción literaria. Adicionalmente, se emplearán otras métricas...
4. **Adaptación de un modelo de lenguaje grande (LLM) al tarea de traducción:** realizar el fine-tuning de un LLM moderno (o antiguo) (como XXX) utilizando el mismo corpus wuxia, para comprobar si estos modelos generalistas pueden alcanzar un rendimiento competitivo o superior en traducción especializada al ser adaptados con una cantidad limitada de datos específicos.
5. **Comparativa y análisis de resultados:** comparar distintos enfoques desarrollados (modelos base especializados vs. modelo grande adaptado), tanto cuantitativamente mediante las métricas definidas, como cualitativamente mediante la inspección manual de traducciones. Este análisis deberá identificar qué tipos de errores comete cada sistema (por ejemplo, errores terminológicos, omisiones, fluidez estilística) y evaluar en qué casos la adaptación al dominio aporta mejoras significativas.

## Método de trabajo (TO-DO)

Se seguirá una metodología de desarrollo iterativa e incremental.. En una primera fase se recopilará una bibliografía relevante sobre traducción automática, adaptación al dominio y evaluación de calidad, y se definirán los criterios para construir el corpus paralelo.

El trabajo se organizará en iteraciones centradas en los distintos objetivos: construcción del corpus, entrenamiento de modelos base, fine-tuning del LLM, y evaluación y análisis de los sistemas. Cada componente será implementado y validado antes de avanzar al siguiente, permitiendo una mejora progresiva del sistema.

...

### **Fases principales del trabajo:**

1. **Estudo de estado do arte:** revisión de trabajos sobre traducción automática del chino al inglés, traducción literaria (especialmente wuxia) y técnicas de adaptación de modelos al dominio. También se estudiarán las herramientas a utilizar (Transformers, LLMs, métricas como BLEU, etc.).

#### **2. Preparación de los datos:**

- a. Selección y recopilación de novelas wuxia en chino y sus traducciones al inglés.
- b. Alineamiento y preprocesado: segmentación, limpieza, normalización y partición del corpus.
- c. Revisión de calidad y elaboración de un glosario básico de términos específicos del dominio.

#### **3. Entrenamiento de modelos base:**

Se realizará una adaptación de modelos de traducción automática al dominio específico del corpus, considerando distintos enfoques según el tipo de modelo y sus capacidades. El objetivo sería evaluar la adaptación de estos modelos al estilo narrativo y el vocabulario específico del wuxia, y compara resultados midiendo la calidad y fiabilidad de la traducción.

4. **Adaptación de un LLM al dominio:** se explorará la adaptación de un modelo de gran tamaño (LLM) al dominio del corpus, utilizando técnicas adecuadas para especializar su comportamiento. Se evaluará su rendimiento frente a los modelos anteriores.

**5. Evaluación y análisis de resultados:**

- a. Evaluación cuantitativa con métricas BLEU, etc
- b. Evaluación cualitativa de ejemplos representativos.
- c. Extracción de conclusiones parciales sobre fortalezas y debilidades de cada enfoque.

**6. Redacción de la memoria:** documentación del proceso, análisis de resultados y conclusiones del proyecto. Se incluirán posibles líneas futuras a desarrollar.