



Anteproxecto TFG

GRAO EN CIENCIA E ENXEÑERÍA DE DATOS

Datos da/o estudante*:

Nome e apelidos	Hugo Silvosa Cuervo
DNI	79343281C
Enderezo electrónico	hugo.silvosa.cuervo@udc.es
Teléfono	654063213

Título (galego)*: Enfoques de traducción automática con modelos de linguaxe en obras wuxia.

Título (castelán)*: Enfoques de traducción automática con modelos de lenguaje en obras wuxia.

Título (inglés)*: Machine translation approaches using language models in wuxia works.

Tipo de proxecto*: De desenvolvemento en investigación

Modalidade de proxecto*: Traballo a proposta do alumno

Dirección:

Máximo dúas persoas da FIC. Permítese unha terceira persoa só no caso de pertencer a outra organización (que hai que especificar):

— Titor(a) da FIC*: Vilares Calvo, David (david.vilares@udc.es)

— Titor(a) da FIC: Gómez Rodríguez, Carlos (carlos.gomez@udc.es)

— Director(a) externo/a:
Organización:

Breve descrición*:

La traducción automática del chino al inglés ha logrado grandes avances con los modelos neuronales de Deep Learning, especialmente en dominios generales. Sin embargo, existen ciertos desafíos al aplicar estos sistemas a géneros literarios específicos, sobre todo cuando existen referencias



culturales específicas. En concreto, las novelas de artes marciales chinas o “wuxia” presentan terminología y contextos profundamente arraigados en la cultura e historia antigua y folclórica de China, así como elementos fantásticos relacionados normalmente con la mitología china (títulos honoríficos, estilos de combate, rituales, conceptos de cultivación, etc.), lo que dificulta su traducción y evaluación mediante modelos genéricos de traducción automática. Como resultado de estas limitaciones, muchas de las traducciones actuales disponibles para novelas wuxia sufren de una falta de coherencia en los términos específicos y posibles errores en matices culturales, lo que afecta a la calidad y legibilidad del texto traducido.

Es por estas razones que la adaptación al dominio ha demostrado ser una vía útil y efectiva para mejorar los resultados de traducción. Al mismo tiempo, los modelos de lenguaje de última generación ya presentan un nivel notable de competencia en tareas de traducción general, por lo que este trabajo busca estudiar en qué medida su especialización con datos específicos del dominio puede mejorar el tratamiento de contenidos literarios, consiguiendo así una comparación entre dos enfoques distintos: modelos diseñados específicamente para traducir frente a modelos generalistas adaptados a una tarea concreta.

Este proyecto se centra en el desarrollo de un sistema de traducción automática adaptado al dominio wuxia para el par de idiomas chino–inglés. Para ello, se construirá un corpus paralelo alineando manualmente textos originales en chino con sus traducciones al inglés, a partir de novelas wuxia representativas (por ejemplo, *Reverend Insanity*, del subgénero “xianxia”, más fantástico, o la trilogía de los Cóndores de Jin Yong, novelas del género “wuxia” más tradicionales). Con este conjunto de datos especializado, se entrenarán y ajustarán modelos de traducción neuronal basados en arquitecturas Transformer. Estos actuarán como sistemas base (baseline), cuyo rendimiento se evaluará tanto cuantitativamente como cualitativamente sobre textos del dominio específico. Posteriormente, se trabajará con modelos de lenguaje de gran tamaño (LLM), con el objetivo de analizar si estos modelos generalistas pueden igualar o superar a los NMT especializados en aspectos como la fluidez, la coherencia narrativa o la sensibilidad estilística del texto.

La efectividad de las traducciones se evaluará con métricas automatizadas estándar y avanzadas. Se considerarán métricas como BLEU, COMET, u otras similares, teniendo en cuenta sus respectivas limitaciones, especialmente en contextos literarios donde las variaciones estilísticas pueden influir en los resultados.

Finalmente, se llevará a cabo una comparación entre los distintos enfoques implementados, que incluirá tanto un análisis cuantitativo, basado en las métricas mencionadas, como un análisis cualitativo a partir de ejemplos de traducción seleccionados. Este último contemplará una evaluación humana que permita identificar en qué la adaptación al dominio mejora la calidad de las traducciones, así como las fortalezas y debilidades de cada solución.

Obxectivos concretos*:

-Construcción de un corpus paralelo especializado: compilar y alinear manualmente un conjunto de datos chino–inglés de novelas wuxia, garantizando la calidad de la traducción de referencia y su adecuación al dominio (terminología y estilo narrativo propios). Este corpus servirá como base para entrenar y evaluar los modelos.

-Entrenamiento de modelos de traducción neuronales base: adaptar al dominio wuxia varios modelos de traducción automática basados en transformadores. Se considerarán modelos como MarianMT, mBart, mT5-small, SMaLL-100 y M2M100. Mediante fine-tuning, cada modelo se entrenará con el corpus especializado para obtener sistemas de traducción enfocados en este tipo de texto.

-Evaluación con métricas adecuadas: aplicar métricas automáticas para medir el rendimiento de las traducciones. Se utilizará BLEU para disponer de un punto de comparación con trabajos previos, examinando sus posibles deficiencias en traducción literaria. Adicionalmente, se emplearán otras métricas complementarias como CHRF2, TER, ROUGHE-L F1 y METEOR, para poder obtener una valoración más completa del rendimiento.

-Adaptación de modelos de lenguaje grande (LLM) a la tarea de traducción: se trabajaría con LLMs utilizando el mismo corpus especializado al dominio wuxia para evaluar si estos modelos generalistas pueden ofrecer un rendimiento competitivo en traducción especializada cuando se trabajan con conjuntos de datos limitados.

-Comparativa y análisis de resultados: comparar distintos enfoques desarrollados (modelos base especializados vs. modelo grande adaptado), tanto cuantitativamente mediante las métricas definidas, como cualitativamente mediante la inspección manual de traducciones. Este análisis deberá identificar qué tipos de errores comete cada sistema (por ejemplo, errores terminológicos, omisiones, fluidez estilística) y evaluar en qué casos la adaptación al dominio aporta mejoras significativas.

Método de traballo*:

Para el desarrollo de este proyecto se seguirá una metodología ágil, adaptada a las necesidades del proyecto y orientada a la experimentación iterativa con modelos de traducción automática. El trabajo se organizará en ciclos breves e iterativos, en los que se irán desarrollando, revisando y mejorando las distintas fases que forman el proyecto. De esta forma, cada iteración permitirá avanzar de forma progresiva, validando los resultados obtenidos y realizando los ajustes necesarios antes de continuar con las fases posteriores.

Durante el desarrollo se mantendrá una revisión constante del progreso, lo que facilitará la detección temprana de errores o desviaciones de los objetivos planteados. A partir de los resultados obtenidos en cada fase, se evaluará la necesidad de introducir cambios metodológicos o de redirigir el enfoque de aspectos del desarrollo para optimizar el rendimiento general del proyecto.

Esta forma de trabajo permitiría incorporar mejoras progresivas a partir de los resultados obtenidos en cada fase. Se justifica el uso de la metodología ágil por su capacidad para adaptarse a las necesidades cambiantes que puede tener un proyecto, facilitando una gestión más eficaz del tiempo y permitiendo alcanzar resultados más sólidos y de mejor calidad.

Fases principais do traballo*:

-Estudio del estado del arte: revisión de trabajos sobre traducción automática del chino al inglés, traducción literaria (especialmente wuxia) y técnicas de adaptación de modelos al dominio. También se estudiarán las herramientas a utilizar (Transformers, LLMs, métricas como BLEU, etc.).

- Preparación de los datos:

Selección y recopilación de novelas wuxia en chino y sus traducciones al inglés.

Alineamiento y preprocesado: segmentación, limpieza, normalización y partición del corpus.

Revisión de calidad del corpus.

-Entrenamiento de modelos base:

Se realizará una adaptación de modelos de traducción automática al dominio específico del corpus,



considerando distintos enfoques según el tipo de modelo y sus capacidades. El objetivo sería evaluar la adaptación de estos modelos al estilo narrativo y el vocabulario específico del wuxia, y compara resultados midiendo la calidad y fiabilidad de la traducción.

Adaptación de un LLM al dominio: se explorará la adaptación de un modelo de gran tamaño (LLM) al dominio del corpus, utilizando técnicas adecuadas para especializar su comportamiento. Se evaluará su rendimiento frente a los modelos anteriores.

-Evaluación y análisis de resultados:

Evaluación cuantitativa con métricas BLEU, etc

Evaluación cualitativa de ejemplos representativos.

Extracción de conclusiones parciales sobre fortalezas y debilidades de cada enfoque.

-Redacción de la memoria: documentación del proceso, análisis de resultados y conclusiones del proyecto. Se incluirán posibles líneas futuras a desarrollar.

Material, medios e recursos necesarios*:

-Conjunto de datos: Las siguientes novelas.

Reverend Insanity (蛊真人) – Gu Zhen Ren.

Condor Trilogy – Jin Yong:

The Legend of the Condor Heroes (射雕英雄传)

The Return of the Condor Heroes (神雕侠侣)

Heaven Sword and Dragon Saber (倚天屠龙记)

A Will Eternal (一念永恒) – Er Gen.

-Lenguaxe de programación: Python 3.X

-Librerías y frameworks:

HuggingFace Transformers: acceso a modelos preentrenados y herramientas de tokenización.

Datasets (HuggingFace): manejo de conjuntos de datos.

Pytorch: framework de entrenamiento para modelos de aprendizaje.

NLTK / SpaCy: para tareas de preprocesamiento y segmentación lingüística en chino e inglés.

-Recursos:

Ordenador personal con tarjeta gráfica NVIDIA GeForce RTX 3060 (12 GB VRAM) y 32 GB de memoria RAM para los modelos pequeños.

Recursos computacionales del CESGA.

Propiedade intelectual do traballo*:

O Regulamento dos Traballos de Fin de Grao da Facultade de Informática da Coruña (aprobado pola Xunta de Centro o 18 de xullo de 2022) establece na sección 4, en relación aos dereitos derivados da propiedade intelectual dos traballos, o seguinte:

4.1. No caso dos traballos desenvolvidos en colaboración cunha entidade externa, a titularidade dos dereitos de propiedade e explotación dos resultados, se for o caso, rexerá polo establecido na relación contractual entre a/o estudante e a entidade externa. Neste caso, quen exerza a dirección académica non será titular dos dereitos de propiedade intelectual, salvo que se establecer doutra maneira nun documento asinado pola/o estudante, o profesorado encargado da dirección e un/ha representante da entidade externa.

4.2. No caso dos traballos desenvolvidos no ámbito do centro, a titularidade dos dereitos de propiedade intelectual, se for o caso, corresponderá á/ao estudante segundo queda recollido no apartado h) do artigo 8 do Real Decreto 1791/2010 do 30 de decembro, salvo que se establecer doutra maneira no anteproxecto asinado pola/o estudante e o profesorado encargado da dirección do TFG.



Os resultados xerados durante a realización do TFG poderán ser utilizados para a docencia na UDC, sempre con autorización e mención explícita de quen ostente a súa autoría.

Indique a continuación se o traballo se realiza en colaboración cunha entidade externa ou no ámbito do centro, e neste último caso, o acordo sobre os dereitos derivados da propiedade intelectual do traballo.

O traballo realízase en colaboración cunha entidade externa: **No**

Nome da empresa:

Se o traballo non se realiza en colaboración cunha entidade externa, indique se os dereitos derivados da propiedade intelectual son compartidos entre a/o estudante e as/os directores: **Sí**

Asinado:

Estudiante

Titoras/es e Directoras/es