



TRABALLO FIN DE GRAO
GRAO EN ENXEÑARÍA INFORMÁTICA
MENCIÓN EN ENXEÑARÍA DO SOFTWARE



Enfoques de traducción automática con modelos de linguaxe en obras wuxia.

Estudante: Nome Completo
Dirección: Outro Nome Completo

A Coruña, abril de 2026.

Dedicatoria

Agradecementos

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Resumo

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Abstract

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn”? Kjift – not at all! A blind text like this gives you information about the selected font, how the letters are written and an impression of the look. This text should contain all letters of the alphabet and it should be written in of the original language. There is no need for special content, but the length of words should match the language.

Palabras chave:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Keywords:

- First itemtext
- Second itemtext
- Last itemtext
- First itemtext
- Second itemtext
- Last itemtext
- First itemtext

Índice Xeral

1	Introdución	1
1.1	Objetivos del Proyecto	4
1.2	Metodología y Planificación Temporal	5
2	Estado del Arte	7
2.1	Traducción automática en dominios específicos	9
2.2	Traducción automática neuronal	10
2.3	Métricas de evaluación	11
3	Materiales y herramientas	13
3.1	Herramientas y Entorno de Trabajo	13
4	Conjunto de datos	15
4.1	Preprocesado y alineación del corpus	17
4.1.1	Limpieza y segmentación estructural.	17
4.1.2	Alineación bilingüe semántica	18
4.1.3	Comparativa de rendimiento	19
4.2	Filtrado de datos	22
4.3	Análisis del corpus	24
5	Enfoques estadísticos de traducción	27
5.1	Fundamentos probabilísticos	28
5.2	Traducción Basada en Frases	29
5.2.1	El fracaso de PBMT en la Traducción literaria Especializada	31
6	Traducción Automática Neuronal	32
6.1	El paradigma Sequence-to-Sequence	32
6.2	Mecanismos de Atención	34
6.2.1	Atención Aditiva (Bahdanau)	35

6.2.2	Atención Multiplicativa (Luong)	35
6.3	La arquitectura Transformer	36
6.3.1	Autoatención y atención multicabezal	36
6.3.2	Codificación posicional y atención cruzada	37
6.4	Segmentación de subpalabras	37
6.5	Selección de modelos	38
6.6	Adaptación al dominio	39
6.7	Entrenamiento	40
7	Grandes modelos de lenguaje	41
7.1	El paradigma <i>Decoder-only</i>	42
7.2	Selección de modelos	43
7.2.1	Llama 3.3 70B Instruct (Meta)	43
7.2.2	GLM-4 32B (Zhipu AI)	44
7.2.3	Gemma 3 27B IT (Google DeepMind)	44
7.2.4	Qwen 3 30B Instruct (Alibaba Cloud)	45
7.3	Métodos de Inferencia e Ingeniería de Prompts	45
7.3.1	Aprendizaje en Contexto (In-Context Learning)	45
7.3.2	Diseño de plantillas de instrucción	46
7.4	<i>Fine-tuning</i>	47
7.4.1	Eficiencia Paramétrica: PEFT y LoRA	48
7.4.2	Cuantización de redes: El protocolo QLoRA	49
7.4.3	Configuración de hiperparámetros experimentales	49
7.4.4	estadísticas del entrenamiento?	50
8	Conclusiones	51
A	Material adicional	54
	Bibliografía	57

Índice de Figuras

1.1	Portada de un libro (izquierda) del género <i>wuxia</i> y un libro (derecha) del género <i>xianxia</i>	2
4.1	Carteles de las películas <i>Legends of the Condor Heroes: The Gallants</i> y <i>Ne Zha 2</i> , publicadas en 2025.	16

Índice de Táboas

4.1	Comparativa de algoritmos de alineación (Umbral de similitud ≥ 0.15)	19
4.2	Análisis lexicométrico: Comparativa del corpus bruto vs. filtrado	26

Introducción

LA traducción automática ha experimentado un cambio importante en la última década, impulsado fundamentalmente por el avance en la implementación de las redes neuronales profundas (*Deep Learning*). Los sistemas de Traducción Automática Neuronal (NMT) sentaron las bases de un nuevo paradigma. Más recientemente, los Modelos de Lenguaje de Gran Tamaño (LLMs) han logrado niveles de fluidez y precisión que, en dominios generales como la documentación técnica, llegan a rivalizar con la capacidad humana. Además, diversas investigaciones han demostrado, tanto mediante métricas automáticas como a través de evaluaciones manuales, que los LLMs de última generación son capaces de generar traducciones con una calidad equiparable a la de traductores profesionales en estos ámbitos especializados [1, 2, 3].

Sin embargo, el rendimiento de estas herramientas no es homogéneo en todos los escenarios y existen nichos que todavía presentan un margen de mejora. Las máquinas aún siguen enfrentándose a obstáculos técnicos cuando debe adaptarse a dominios especializados, procesar lenguas con escasos recursos digitales o trabajar con pares de idiomas tipológicamente distantes, donde las discrepancias culturales imponen barreras semánticas complejas. Es aquí donde la traducción literaria se muestra como uno de los territorios más complejos y menos conquistados por la inteligencia artificial. A diferencia del texto técnico, donde lo importante es la precisión literal, la literatura exige la preservación de la voz narrativa, el estilo, el ritmo y, crucialmente, el contexto cultural que da sentido a la obra.

Esta problemática se complica aún más cuando se aborda la traducción entre pares de idiomas lingüísticamente diferentes y culturalmente divergentes, como es el caso del chino mandarín y el inglés. Dentro de este ámbito, destacan dos géneros literarios de fantasía china que representan un caso de estudio para el procesamiento del lenguaje natural: el *wuxia* (héroes marciales), que relata las hazañas de héroes marciales humanos y el *xianxia* (héroes

inmortales), centrado en la alta fantasía y la búsqueda de la inmortalidad.



Figura 1.1: Portada de un libro (izquierda) del género *wuxia* y un libro (derecha) del género *xianxia*.

Estas obras literarias no solo presentan estructuras narrativas complejas, sino que además están construidas sobre un léxico especializado profundamente arraigado en el daoísmo, el budismo, la medicina tradicional china y las artes marciales. Conceptos como *Qi* (energía vital), *Dantian* (centro energético), afecciones fisiológico-espirituales como el *Zouhuo Rumu*¹ o los niveles de “cultivo” espiritual, como la etapa del *Yuanying*², no tienen equivalentes directos en la lengua inglesa y requieren estrategias de traducción que van más allá de la literalidad, exigiendo una adaptación cultural que los modelos genéricos pueden no llegar a cumplir.

El propósito de esta investigación sería entonces explorar, implementar y evaluar técnicas de adaptación de dominio (*Domain Adaptation*). Esta metodología se plantea como una solución directa a la problemática descrita. Para ello, el estudio se apoyará en modelos especializados de Traducción Automática Neuronal especializados, que han dominado el campo desde 2017, y en los emergentes Modelos de Lenguaje de Gran Tamaño generativos.

Para comprender la complejidad técnica de este proyecto, es fundamental desglosar las características que hacen del *Wuxia* y el *Xianxia* un dominio excepcional. Los traductores

¹ Literalmente “el fuego se escapa y entra el demonio”. Se refiere al colapso físico o mental que sufre un practicante cuando su entrenamiento falla. Los traductores humanos suelen acuñar el término inglés *Qi Deviation* (Desviación de Qi) para evitar que la traducción literal se interpretara erróneamente como una posesión demoníaca de sentido literal.

² Su traducción literal es “infante original”, refiriéndose a una etapa taoísta donde la energía forma un ente metafísico en el interior del cultivador. La comunidad lo estandarizó como *Nascent Soul* (Alma Naciente), ya que la traducción literal de un personaje atacando con su “bebé original” arruinaba el tono épico del texto.

automáticos convencionales operan bajo la premisa de una equivalencia semántica directa entre idiomas. Sin embargo, al enfrentarse a esta literatura, los sistemas sufren una severa crisis de cambio de dominio (*domain shift*) motivada por tres grandes retos lingüísticos:

- **Falta de equivalencia semántica directa:** El término *Jianghu* (江湖) se traduce literalmente como “ríos y lagos” en un motor genérico. No obstante, para el lector del género, este concepto no describe una geografía. Representa el submundo de los artistas marciales, un ecosistema al margen de la ley imperial con sus propios códigos de honor y violencia. Una traducción literal rompe instantáneamente la inmersión narrativa.
- **Terminología metafísica y de cultivo:** Expresiones como “cultivar el Dao” o “refinar el Alma Naciente” son el núcleo de estas obras. Un modelo no adaptado suele interpretar el concepto de “cultivación” (修炼) en un sentido puramente agrícola. Esta disonancia semántica genera oraciones absurdas sobre granjeros, fallando por completo al describir la ascensión espiritual de monjes inmortales.
- **Ambigüedad jerárquica y relacional:** La ambigüedad intrínseca de los caracteres chinos exige un profundo conocimiento del contexto histórico y filosófico para su correcta desambiguación. En las sectas marciales, términos como *Shixiong* (“hermano marcial mayor”) o *Shishu* (“tío marcial”, en referencia al hermano mayor del maestro) definen posiciones estrictas de autoridad y respeto generacional. Los modelos genéricos suelen traducirlos como simples vínculos de sangre, confundiendo la jerarquía de la secta con relaciones familiares. Esta pérdida de cohesión terminológica degrada severamente los matices estilísticos del texto original.

Esta barrera lingüística choca frontalmente con la realidad del mercado. El auge de la literatura web china ha impulsado una fuerte demanda internacional a través de plataformas oficiales como Webnovel (filial de Qidian) y comunidades de traducción como Wuxiaworld. Sin embargo, el modelo de negocio oficial se basa en la publicación racionada, liberando apenas uno o dos capítulos diarios de obras que a menudo superan los miles de episodios. Ante la lentitud de la oferta oficial, los lectores recurren masivamente a la traducción automática. Hasta hace poco, estos sistemas producían textos incomprensibles o excesivamente literales, perdiendo por completo la estética poética y marcial que define al género.

Frente a esta situación hay dos enfoques que buscan darle una solución. Por un lado, la adaptabilidad de modelos neuronales específicos mediante *fine-tuning* permite inyectar un conocimiento sobre el dominio de forma controlada. Por otro lado, la irrupción de los LLMs ofrece un cambio de paradigma. Estos sistemas albergan una vasta cantidad de conocimiento implícito en sus parámetros, dotándolos de una comprensión profunda del contexto narrativo. Además, estudios recientes demuestran que exhiben notables capacidades creativas en la

redacción [4, 5], llegando incluso a superar la creatividad humana en textos cortos [6]. Esta habilidad justifica su uso en la traducción literaria para asimilar la prosa poética del género, aunque conlleve una mayor propensión a las denominadas alucinaciones: la tendencia del modelo a generar texto muy fluido, pero inventado o desviado del significado original.

1.1 Objetivos del Proyecto

El objetivo principal de este Trabajo de Fin de Grado es desarrollar, implementar y validar un marco de trabajo especializado para la traducción automática del dominio *wuxia/xianxia*, comparando la efectividad de las arquitecturas de traducción neuronal frente a las capacidades de los modelos de lenguaje de gran tamaño, analizando qué enfoque mitiga mejor las disonancias semánticas y si resulta viable elevar el estándar de la traducción automática para ofrecer un texto comprensible que preserve el estilo específico que exige el lector de *wuxia*.

Este propósito central se divide los siguientes objetivos:

1. Crear un Corpus Wuxia: un conjunto de datos paralelo de calidad para el entrenamiento y la evaluación de los modelos. Esta tarea consiste en recopilar y alinear oraciones de chino simplificado con traducciones humanas de obras como la “Trilogía del Cóndor” o “Reverend Insanity”. La limpieza y normalización de este corpus sería crucial para asegurar una consistencia en términos fundamentales del género, evitando que el ruido textual afecte negativamente a la convergencia de los modelos.
2. Especializar modelos NMT basados en Transformers, contrastando arquitecturas ligeras frente a modelos multilingües más potentes. El fin es evaluar el impacto del preentrenamiento en la adaptación a un dominio de recursos limitados y determinar si el ajuste fino supervisado logra corregir la literalidad mecánica de los traductores genéricos.
3. Abordar la adaptación de modelos LLM. Por un lado, se investigará cómo la aplicación de técnicas de *prompt engineering* y aprendizaje en contexto (*few-shot learning*) puede guiar a los modelos generalistas para que asimilen el tono narrativo y la terminología del género sin incurrir en altos costes de entrenamiento. Por otro lado, se explorará el uso de LoRA para realizar un ajuste fino (*fine-tuning*), lo que permitirá contrastar los resultados de la mera provisión de contexto frente a un entrenamiento adaptado específicamente al dominio. Esta comparativa es esencial para entender si la capacidad de razonamiento semántico de los LLMs compensa su menor especialización léxica en comparación con los modelos NMT dedicados.

4. Medir los resultados del proyecto mediante una evaluación basada en un conjunto diverso de métricas, con el propósito de capturar los distintos matices y sutilezas de la traducción. Este planteamiento busca abarcar el espectro más amplio posible de la calidad textual, sin que se penalice la creatividad de las traducciones a favor de la literalidad. Asimismo, este análisis automático se complementará con una evaluación cualitativa humana sobre fragmentos para juzgar la coherencia narrativa, la fluidez estilística y el respeto por la terminología del “cultivo”.

1.2 Metodología y Planificación Temporal

Para el desarrollo de este proyecto se seguirá una metodología ágil, adaptada a las necesidades del proyecto y orientada a la experimentación iterativa con modelos de traducción automática. El trabajo se organizará en ciclos breves e iterativos, en los que se irán desarrollando, revisando y mejorando las distintas fases que forman el proyecto. De esta forma, cada iteración permitirá avanzar de forma progresiva, validando los resultados obtenidos y realizando los ajustes necesarios antes de continuar con las fases posteriores.

Durante el desarrollo se mantendrá una revisión constante del progreso, lo que facilitará la detección temprana de errores o desviaciones de los objetivos planteados. A partir de los resultados obtenidos en cada fase, se evaluará la necesidad de introducir cambios metodológicos o de redirigir el enfoque de aspectos del desarrollo para optimizar el rendimiento general del proyecto. Esta forma de trabajo permitiría incorporar mejoras progresivas a partir de los resultados obtenidos en cada fase, facilitando una gestión más eficaz del tiempo y permitiendo alcanzar resultados más sólidos y de mejor calidad.

A continuación se detalla la hoja de ruta cronológica:

Tiempos pendientes

1. Ciclo I: Familiarización con el estado del arte en la literatura. Esta fase se centra en sentar las bases teóricas del proyecto, investigar la bibliografía técnica pertinente y sistematizar la terminología compleja propia del género literario.
2. Ciclo II: Definición tecnológica. Comprende la especificación de los requisitos técnicos y la selección de los modelos que se van a emplear.
3. Ciclo III: Extracción y preparación de datos. Consiste en la recopilación y limpieza de los textos de las novelas seleccionadas. El objetivo es construir un corpus *wuxia* perfectamente alineado y estructurado en particiones de entrenamiento, validación y prueba (*test*).

4. Ciclo IV: Entrenamiento de modelos NMT. Etapa de experimentación empírica dedicada al entrenamiento y ajuste fino (*fine-tuning*) de las redes neuronales de traducción. En esta fase se establecerá el rendimiento base (*baseline*) que servirá como punto de referencia.
5. Ciclo V: Adaptación de LLMs. Abarca la ejecución de pruebas de inferencia, la aplicación de técnicas de *prompt engineering* e *in-context learning* así como la implementación del *fine-tuning* en los modelos seleccionados.
6. Ciclo VI: Evaluación y validación. Fase destinada a la medición del rendimiento mediante un conjunto de métricas automáticas, complementada con una revisión cualitativa humana. El propósito es contrastar los distintos enfoques analizados y evaluar la calidad real de las traducciones generadas.
7. Ciclo VII: Cierre y documentación. Consolidación de los datos obtenidos, extracción de conclusiones y redacción final de la memoria del proyecto.

Diagrama de gantt pendiente.

Estado del Arte

EL campo del Procesamiento del Lenguaje Natural (PLN), incluyendo la traducción automática, no puede comprenderse sin analizar la evolución tecnológica que ha experimentado específicamente esta última disciplina durante las últimas décadas. Su historia se remonta a la Guerra Fría, cuando el memorándum de W. Weaver *Translation* [7] propuso por primera vez utilizar computadoras criptográficas para descifrar lenguajes humanos como si fueran códigos, sentando las bases teóricas y operativas para el diseño de los primeros sistemas de traducción automática. Durante las décadas siguientes, el sector estuvo dominado por la Traducción Automática Basada en Reglas (RBMT, por sus siglas en inglés), que dependían de diccionarios bilingües estáticos y estructuras gramaticales codificadas a mano por lingüistas. Este enfoque resultó ser excesivamente rígido e inescalable, dando paso en los años noventa a la Traducción Automática Estadística (SMT), impulsada principalmente por investigadores como P. F. Brown et al. [8, 9]. La SMT introdujo el concepto de modelado probabilístico, analizando grandes corpus para predecir secuencias de n-gramas. Aunque este nuevo enfoque supuso una mejora notable, su principal limitación radicaba en la fragmentación del contexto. Al trocear el texto, la probabilidad de generar una palabra dependía exclusivamente de una ventana local e inmediata de términos anteriores, por lo que al considerar únicamente este contexto cercano, tanto en la secuencia de origen como en la de destino, el modelo perdía por completo el rastro de las dependencias sintácticas a largo plazo. En consecuencia, generaba textos fragmentados, carentes de fluidez y de la cohesión necesaria para devolver traducción literaria correcta.

Aunque las primeras incursiones de las redes neuronales en este campo se apoyaron en enfoques más elementales, como el uso de perceptrones y ventanas deslizantes, el verdadero cambio de paradigma en la Traducción Automática Neuronal se consolidó con la adopción de las arquitecturas de secuencia a secuencia (Seq2Seq). Estos modelos se construyeron inicialmente sobre Redes Neuronales Recurrentes (RNN). La gran innovación radicaba en que

la red ‘leía’ la oración completa, la comprimía en un vector numérico de longitud fija en un espacio latentes y, a partir de ahí, la decodificaba en el idioma de destino. Sin embargo, las RNN presentaban un serio cuello de botella computacional: su naturaleza secuencial obligaba a procesar las palabras una por una, imposibilitando la paralelización. Además, a medida que la longitud de oraciones aumentaba la red sufría el problema del desvanecimiento del gradiente, olvidando el principio de la frase para cuando llegaba al final.

El paradigma cambió definitivamente con la publicación del artículo *Attention is All you Need* de A. Vaswani et al. [10]. Este trabajo prescindió radicalmente de la recurrencia y propuso una nueva arquitectura, conocida como Transformer, que fue evaluada originalmente en tareas de NMT del inglés al alemán y al francés. Su éxito se basó en el mecanismo de auto-atención (*Self-Attention*) y la atención multicabezal (*Multi-Head Attention*). Estos mecanismos permiten que la red neuronal calcule dinámicamente la relevancia de cada palabra de una frase respecto a todas las demás de forma simultánea, sin importar cuán separadas estén del texto. Al incorporar una codificación posicional (*Positional Encoding*) para no perder el orden sintáctico, el Transformer permitió un entrenamiento masivamente paralelizable en GPUs. El impacto fue inmediato: los Transformers consiguieron los mejores resultados hasta la fecha de calidad de traducción (medidos en BLEU) y dieron paso a sistemas escalables, posibilitando el diseño de arquitecturas mucho más grandes y profundas. Esta capacidad técnica, unida a la adopción generalizada de fases de preentrenamiento masivo, convirtió a los Transformers en la base indiscutible del procesamiento del lenguaje natural moderno.

Esta capacidad técnica impulsó la adopción generalizada del preentrenamiento masivo, dando lugar a modelos basados en esta arquitectura como BERT [11] o RoBERTa [12]. Estas redes se entrenan sobre volúmenes gigantescos de texto monolingüe para asimilar representaciones lingüísticas profundas antes de enfrentarse a una tarea específica. En el ámbito de la traducción automática, este avance modificó las estrategias de desarrollo: en lugar de entrenar modelos desde cero, estas arquitecturas preentrenadas se integran en los sistemas NMT, usualmente inicializando las capas del codificador, para luego someterse a un proceso de *fine-tuning* sobre corpus paralelos [13, 14]. Este enfoque permite transferir todo el conocimiento semántico y sintáctico general previamente adquirido hacia la tarea de traducción, mejorando notablemente la coherencia y calidad del texto final.

2.1 Traducción automática en dominios específicos

Una vez superada la barrera del procesamiento secuencial, la investigación en traducción automática afrontó una nueva limitación: la dependencia de grandes corpus bilingües. Los modelos neuronales requerían grandes corpus bilingües para su entrenamiento, lo cual limitaba su aplicación en lenguas minoritarias o en dominios textuales específicos sin traducciones previas, desplazando el foco desde el entrenamiento exclusivo con datos paralelos hacia el aprovechamiento masivo de textos monolingües. Para afrontar esta carencia de datos, se adoptó la metodología *Encoder-Decoder*, un diseño que permite a la red procesar el contexto global de la oración fuente mediante un codificador bidireccional antes de iniciar la generación del texto, y que posteriormente se combinó con el aprendizaje por transferencia (*transfer learning*). Esta evolución dio lugar al paradigma de transferencia de texto a texto, popularizado por modelos como BART [15] y T5 [16], los cuales operan como auto-codificadores de eliminación de ruido (*denoising autoencoders*). En esta configuración, el modelo se preentrena introduciendo alteraciones deliberadas en textos monolingües, como el enmascaramiento o la eliminación de palabras, y forzando a la red a reconstruir el texto original. El propósito de esta fase de preentrenamiento es dotar al modelo de una comprensión profunda de la sintaxis y la semántica del idioma antes de enfrentarse a ninguna tarea específica, reduciendo drásticamente la necesidad de datos etiquetados en fases posteriores.

El avance en este paradigma sentó las bases para abordar el desafío de las lenguas minoritarias y los dominios hiperespecializados, entornos caracterizados por la escasez de datos paralelos y conocidos como escenarios de bajos recursos (*low-resource*). La aplicación de estas técnicas de preentrenamiento en entornos multilingües permitió el desarrollo de modelos como mBART [17], demostrando que una red inicializada en múltiples idiomas podía adaptarse eficientemente a dominios concretos mediante un ajuste fino con conjuntos de datos muy reducidos. Esta misma filosofía impulsó la creación de modelos de traducción de gran capacidad, tales como M2M-100 [18], capaz de traducir directamente entre múltiples idiomas sin utilizar el inglés como lengua puente, y NLLB-200 [19], diseñado específicamente para extender las traducciones a lenguas marginadas digitalmente (*No Language Left Behind*).

Por otro lado, surge el problema del cambio de dominio. Aunque los modelos logran un buen rendimiento con textos generales (noticias, actas o webs), su eficacia se degrada drásticamente al aplicarse a un nicho con una distribución léxica y estilística diferente. Como demostraron M. Müller et al. en el artículo *Domain robustness in neural machine translation* [20], esta divergencia no solo reduce la calidad, sino que dispara la aparición de alucinaciones ante vocabulario desconocido. Para mitigarlo, se aplica la Adaptación de Dominio (*Domain*

Adaptation) mediante *fine-tuning*. Sin embargo, estudios como los de Chu y Wang [21] y Koehn [22] advierten que este proceso conlleva un enorme riesgo de sobreajuste (*overfitting*): al forzar a la red a memorizar un nicho, el modelo se vuelve rígido y pierde su fluidez lingüística original.

2.2 Traducción automática neuronal

Adicionalmente, la traducción literaria presenta un otro problema más: la pérdida de coherencia narrativa a nivel de documento. Dado que los sistemas NMT clásicos suelen traducir oración por oración, el modelo no retiene información contextual amplia. Esto provoca inconsistencias a lo largo de un capítulo, como alteraciones en el género de los personajes o en los tiempos verbales. Para responder a la necesidad de procesar contextos más extensos, la industria escaló la rama *Decoder-only* del Transformer. Al centrarse en predecir el siguiente *token* de forma secuencial, esta arquitectura resultó computacionalmente más eficiente para el escalado. Dicha ventaja facilitó su entrenamiento sobre volúmenes masivos de texto, dando lugar a los Modelos de Lenguaje de Gran Tamaño, más conocidos como *LLMs*. Aunque no fueron concebidos originalmente como traductores, el estudio fundacional de T. B. Brown et al. *Language models are few-shot learners* [23] sobre GPT-3 demostró que la traducción surgía como una capacidad emergente (*few-shot learning*) derivada de su vasta base de conocimientos. La gran ventaja que aportan los *LLMs* a la literatura reside precisamente en su inmensa ventana de contexto, capaz de procesar fragmentos mucho más amplios. Investigaciones recientes como la de Karpinska e Iyyer [24] han confirmado empíricamente que estos modelos son sustancialmente superiores al NMT clásico a la hora de preservar la coherencia narrativa y el estilo en documentos completos. Asimismo, mediante *prompt engineering*, es posible orientar el estilo de salida del modelo e integrar glosarios en tiempo real, todo ello sin necesidad de alterar los parámetros internos de la red [25, 26].

A pesar de sus capacidades contextuales, el uso de *LLMs* en la traducción literaria presenta un problema inherente a su naturaleza probabilística: la alucinación [27]. Estos modelos están diseñados para optimizar la fluidez generativa por encima de la fidelidad estructural [28]. Como consecuencia, tienden a inventar información ausente en el texto original o a omitir pasajes de alta complejidad. Este defecto de adición y omisión se ha evidenciado de forma sistemática tanto en arquitecturas de traducción dedicadas como en modelos de lenguaje generalistas [29, 30].

Por otro lado, el texto generado por IA sufre un proceso de homogeneización y simplifi-

cación estructural. Investigadores como E. Vanmassenhove et al. [31] y Y. Bizzoni et al. [32] han demostrado mediante análisis sintácticos que estas traducciones pierden riqueza morfológica y asimilan la sintaxis del idioma origen. Además, la literatura científica advierte que los LLMs tienden a estandarizar el lenguaje. En la práctica, los modelos operan como un redactor promedio situado en el percentil 50 de habilidad creativa [33]. Esta convergencia estadística produce textos con una diversidad léxica marcadamente inferior a la de los expertos humanos [34]. A largo plazo, esta falta de originalidad y sesgo hacia la uniformidad amenaza incluso con provocar el colapso de los modelos si se retroalimentan con sus propios datos [33].

2.3 Métricas de evaluación

Este desarrollo de arquitecturas enfrenta también otro desafío metodológico: la evaluación objetiva de la calidad literaria. Durante años, la métrica BLEU [35] ha sido el estándar de evaluación, calculando la superposición exacta de secuencias de palabras entre la salida de la máquina y una referencia humana. El problema central de BLEU es que penaliza severamente las divergencias léxicas: si un modelo genera una oración correcta y fluida pero emplea sinónimos o un orden gramatical distinto al de la referencia estática, la métrica asignará una puntuación baja, castigando la creatividad. Para mitigar estas deficiencias, las métricas de evaluación han experimentado una evolución continua. Inicialmente, surgieron alternativas como TER (*Translation Edit Rate*) [36], que en lugar de buscar coincidencias exactas, se enfocó en medir el esfuerzo real de posesición calculando las modificaciones necesarias para alcanzar la referencia humana. Posteriormente, para gestionar mejor la riqueza morfológica y las variaciones léxicas menores, la comunidad adoptó métricas como chrF [37], que desplazó el cálculo de la superposición del nivel de palabra al nivel de carácter. Sin embargo, todas estas aproximaciones seguían ancladas a comparaciones de superficie. El salto definitivo se ha producido en los últimos años con la irrupción de métricas basadas en redes neuronales y *embeddings* contextuales, destacando modelos como BERTScore [38], BLEURT [39] y COMET [40]. La idea detrás de estos enfoques es evaluar la similitud semántica general entre la hipótesis y la referencia, priorizando que el significado se transmita correctamente independientemente del vocabulario exacto utilizado.

Estudios sobre la capacidad real de la IA en la traducción de novelas, como *What level of quality can neural machine translation attain on literary text?* de Toral y Way [41] demostraron de forma concluyente que las métricas automáticas y los esquemas rígidos de evaluación de software subestiman sistemáticamente las traducciones humanas. Los marcos evaluativos estrictos penalizan la creatividad estética intencionada del traductor humano, sugiriendo que

la evaluación cualitativa es el único método válido para identificar el verdadero significado literario. El estudio *How Good Are LLMs for Literary Translation, Really? Literary Translation Evaluation with Humans and LLMs* de Zhang et al. [42], a través del análisis de la aplicación de las Métricas de Calidad Multidimensional (MQM) en textos literarios llegan a una conclusión similar, en que los métodos evaluación estrictos pueden penalizar las decisiones de estilo del traductor humano, aunque sugieren el uso de esquemas comparativos como el Best-Worst Scaling (BWS) para la valoración cualitativa.

Este Trabajo de Fin de Grado se sitúa precisamente en este cruce entre la escasez de recursos y la traducción literaria. En concreto, la investigación se centra en un caso de estudio de alta exigencia cultural: la literatura web fantástica china. Esta narrativa engloba géneros con un vocabulario sumamente especializado, como el *Wuxia* (héroes marciales) y el *Xianxia* (héroes inmortales).

El principal obstáculo radica en que gran parte de esta terminología carece de equivalentes occidentales directos. Una traducción puramente literal por parte de modelos genéricos destruye de inmediato la inmersión y la coherencia de la obra. Investigaciones recientes como la de Kan y Li [43] evidencian que preservar la identidad estructural y cultural de estos textos es imperativo, dado que su estilo difiere radicalmente de la fantasía heroica occidental clásica. Asimismo, desde una perspectiva sociológica, el artículo *Translating chinese identity crisis in and beyond jianghu: A case study of legends of the condor heroes* de Xiaodi Ni [44] destaca que una traducción automática efectiva debe gestionar activamente esta brecha para exportar con éxito la idiosincrasia china al mundo angloparlante.

Como respuesta a los desafíos teóricos y técnicos expuestos a lo largo de este capítulo, el presente proyecto plantea una evaluación empírica de dos paradigmas frente a este reto. En primer lugar, se analiza el rendimiento del ajuste fino en arquitecturas *Encoder-Decoder*. Frente a esto, se examinarán las capacidades de los LLMs, poniendo a prueba las tres estrategias fundamentales que ofrecen para asimilar este vocabulario: la ingeniería de instrucciones, el aprendizaje en contexto y su propio proceso de *fine-tuning*. En última instancia, el propósito de esta comparativa es determinar qué enfoque logra mitigar mejor el cambio de dominio y trasladar con mayor fidelidad la profunda complejidad de la literatura oriental.

Materiales y herramientas

EL rendimiento de los sistemas de traducción automática y de los grandes modelos de lenguaje está directamente limitado por la calidad de sus datos de entrenamiento. En el ámbito del procesamiento del lenguaje natural, los corpus paralelos son la herramienta fundamental: proporcionan los ejemplos necesarios para que las arquitecturas de aprendizaje profundo inferan equivalencias probabilísticas, morfológicas y semánticas entre unidades lingüísticas de diferentes idiomas, permitiendo a los modelos superar la traducción literal y alcanzar resultados fiables.

Este capítulo tiene un propósito doble. Por un lado, documenta el desarrollo y la configuración de las herramientas tecnológicas necesarias para todo el proyecto, es decir, la infraestructura que sustenta los propios sistemas de traducción automática. Por otro, detalla los materiales y la metodología empleada para construir un corpus paralelo chino-inglés de alta fidelidad, enfocado exclusivamente en los géneros literarios wuxia y xianxia. La singularidad de esta literatura, caracterizada por una profunda densidad cultural, terminología filosófica y conceptos de artes marciales justifica la necesidad de un conjunto de datos especializado, debido a que las traducciones genéricas suelen adolecer padecer de falta de coherencia y errores graves al interpretar estas matices.

3.1 Herramientas y Entorno de Trabajo

A continuación, se detalla el conjunto de herramientas de software empleado, agrupado según su función en la investigación.

En primer lugar, el lenguaje de programación base para la totalidad del proyecto ha sido:

- **Python 3.X** [45]: Su entorno integral permite unificar la automatización de recolección

de datos, el análisis estadístico y el diseño de la arquitectura neuronal bajo un mismo paradigma.

Respecto a los *frameworks* de aprendizaje profundo y modelado de lenguaje, la arquitectura neuronal se ha apoyado en las siguientes librerías:

- **PyTorch [46]:** Se ha empleado como entorno principal para la implementación y el entrenamiento de los modelos. Su arquitectura, basada en grafos computacionales dinámicos, permite una depuración directa del código y facilita la manipulación de tensores multidimensionales durante el cálculo de la función de pérdida y el algoritmo de *backpropagation*.
- **Hugging Face Transformers [47]:** Esta biblioteca de código abierto actúa como interfaz para descargar e implementar arquitecturas basadas en Transformers preentrenadas. Permite el acceso directo a los puntos de control (*checkpoints*) de modelos como MarianMT, mBart o Gemma, así como la utilización de sus respectivos tokenizadores.
- **Hugging Face Datasets [48]:** Librería altamente optimizada para el manejo de conjuntos de datos. Emplea un sistema de mapeo de memoria respaldado por Apache Arrow, lo que garantiza que la ingesta de cientos de miles de líneas de texto se realice de forma eficiente sin saturar la memoria del sistema.

Para la ejecución de tareas de procesamiento lingüístico (PLN clásico), se han integrado las siguientes herramientas:

- **NLTK [49] y SpaCy [50]:** Ambas bibliotecas se han utilizado en las etapas iniciales del conducto para ejecutar tareas críticas de segmentación lingüística, análisis de dependencias superficiales y segmentación oracional (*sentence splitting*) tanto para el texto en chino original como para la traducción inglesa.

Finalmente, como herramientas de vectorización y alineación para el corpus, se ha usado:

- **Modelo LaBSE (Language-Agnostic BERT Sentence Embedding) [51]:** Un modelo de representación semántica multilingüe. Este modelo genera vectores densos (de 768 dimensiones) proyectando oraciones de distintos idiomas en un espacio semántico compartido, lo que permite evaluar la equivalencia translacional mediante la similitud del coseno.

Conjunto de datos

EL rendimiento de un modelo de traducción especializado depende directamente de los textos utilizados durante su entrenamiento. Si se emplean datos genéricos para procesar literatura asiática, los sistemas automáticos presentan deficiencias. En la práctica, son incapaces de trasladar adecuadamente las metáforas, la terminología específica o los modismos tradicionales (como los *chengyu*¹, por ejemplo, 胸有成竹, que literalmente se traduce como “tener un bambú adulto en el pecho” pero significa tener un plan trazado y certeza de éxito, o 卧虎藏龙, literalmente “tigre acostado, dragón escondido”, para referirse a talentos excepcionales que pasan desapercibidos). Por ello, la selección de fuentes para este corpus se basó en un criterio principalmente de representatividad, priorizando aquellas obras que integran de forma natural las características estilísticas y culturales propias de la fantasía china.

Tal y como se ha introducido brevemente en el Capítulo 1, el corpus paralelo se estructura en torno a obras divididas en dos subgéneros literarios intrínsecamente relacionados pero con tonos narrativos diferenciados: el *wuxia* y el *xianxia*.

El género *wuxia* se ambienta tradicionalmente en épocas históricas o pseudo-históricas de la antigua China. Sus narrativas están protagonizadas por artistas marciales (*xia*) que operan en un submundo al margen de la ley (el *jianghu*), rigiéndose por un código ético de lealtad, justicia y venganza. Los elementos fantásticos en el *wuxia* son sutiles, centrados en proezas físicas exageradas derivadas del control de la energía interna (*qi*).

Para representar el clasicismo del *wuxia*, el corpus integra una de las obras más influyentes del género del siglo XX: la “Trilogía del Cóndor” (Condor Trilogy), escrita por el aclamado autor Jin Yong. Esta saga, que comenzó su publicación seriada en 1957, está compuesta por

¹ Los *chengyu* (成语) son expresiones idiomáticas tradicionales chinas compuestas, por regla general, de cuatro sinogramas. Su significado es denso y no suele ser deducible de la traducción literal de sus caracteres individuales, ya que hace referencia a metáforas, mitos o relatos históricos de la literatura clásica.

tres novelas: *The Legend of the Condor Heroes* (射鵰英雄傳) [52], *The Return of the Condor Heroes* (神鵰俠侶) [53] y *The Heaven Sword and Dragon Saber* (倚天屠龍記) [54]. La inclusión de la prosa de Jin Yong asegura que el corpus contenga un estilo literario tradicional, formal, rico en alusiones poéticas y descripciones precisas, estableciendo un pilar lingüístico conservador para los modelos de aprendizaje.

Por otro lado, el *xianxia* representa una evolución expansiva del *wuxia*, fuertemente influenciada por la mitología china, la alquimia taoísta, el budismo y el confucianismo. En estas obras, los protagonistas son “cultivadores” que meditan, absorben energía cósmica y superan tribulaciones celestiales con el objetivo final de trascender la mortalidad. El marco narrativo se expande, incorporando deidades, demonios y artefactos mágicos.



Figura 4.1: Carteles de las películas *Legends of the Condor Heroes: The Gallants* y *Ne Zha 2*, publicadas en 2025.

Para capturar la modernidad y el dinamismo del *xianxia*, se seleccionaron dos de las novelas web (*webnovels*) contemporáneas más populares a nivel global: *Reverend Insanity* (盡真人) [55], iniciada en 2012 bajo el seudónimo Gu Zhen Ren, y *A Will Eternal* (一念永恒) [56], escrita por Er Gen y publicada a partir de 2016. Estas obras introducen un registro lingüístico radicalmente distinto, propio de la literatura nativa digital: un ritmo narrativo ágil, diálogos que alternan constantemente entre un tono solemne y un registro coloquial, y un extenso vocabulario para describir los sistemas de cultivo y las jerarquías de poder.

Los criterios que guiaron esta selección fueron principalmente tres:

- **Representatividad de estilo y lenguaje:** Para evitar que el modelo se sobreajuste a un único autor o periodo, se han incluido obras de distintas épocas. La coexistencia del

estilo clásico y estructurado de la “Trilogía del Cóndor” junto a la prosa más directa y dinámica de las novelas *xianxia* contemporáneas permite evaluar modelos en un entorno más diverso y así determinar que modelos son capaces de generalizar mejor a través de distintos registros de la literatura china, capaz de generalizar diferentes registros de la literatura china.

- **Disponibilidad de traducción profesional:** La calidad de un corpus paralelo está estrictamente limitada por la calidad y realismo de las salidas de referencia. Por ello, se descartaron traducciones automáticas previas o proyectos de traducciones de fans. Solo se admitieron textos cuya traducción al inglés hubiese sido ejecutada por traductores profesionales, considerándose versiones oficiales o de calidad cuasi-editorial. Esto garantiza que el corpus parta de un estándar de excelencia humana, sirviendo como referencia fiable tanto para el entrenamiento de modelos como para la evaluación de sistemas preentrenados.
- **Diversidad léxica y complejidad cultural:** Los textos seleccionados deben incluir aquellos ejemplos que habitualmente confunden a los sistemas automáticos. Las novelas elegidas incluyen descripciones ambientales altamente poéticas, nomenclaturas de jerarquías de clanes, y, fundamentalmente, nombres de técnicas marciales y manuales de entrenamiento que requieren una traducción interpretativa y culturalmente consciente, más que una transposición literal palabra por palabra.

4.1 Preprocesado y alineación del corpus

La disparidad en los orígenes de las fuentes requirió estructurar una fase específica de preprocesamiento de datos. Dado que las novelas se extrajeron de plataformas web, los textos originales contenían elementos ajenos a la narración (metadatos, etiquetas o caracteres no estandarizados) que podían comprometer la calidad del entrenamiento del modelo. El flujo se estructuró en tres fases principales: limpieza, segmentación y alineación bilingüe.

4.1.1 Limpieza y segmentación estructural.

En una primera fase, dado que el formato de publicación seriada de las *webnovels* chinas introduce una cantidad significativa de texto ajeno a la narrativa, se procedió a la limpieza estructural del corpus. Inicialmente, se llevó a cabo un análisis exploratorio manual para identificar los patrones recurrentes de este ruido textual. Entre los elementos documentados destacaban los avisos automáticos de las plataformas de publicación (ej. “未完待续”), las peticiones de interacción dirigidas a los lectores (“求月票”) y los comentarios o glosarios insertados por los traductores al final de cada capítulo.

A partir de estos casos localizados, se programó un *script* automatizado basado en el emparejamiento de expresiones regulares (RegEx), eliminando de forma sistemática dichas secuencias a lo largo de todo el corpus, garantizando que estos metadatos no interfirieran en el entrenamiento de los modelos neuronales.

Tras la limpieza, se aplicó una tokenización adaptada a cada idioma. En chino, se utilizaron los signos de cierre nativos de ancho completo (“ ”, “! ”, “? ”). En el caso del inglés, para evitar que abreviaturas comunes (ej. “Dr.”) generasen falsos límites de oración que desalinearan los textos paralelos, se implementó el algoritmo Punkt de la biblioteca NLTK [49]. Este modelo estadístico opera mediante la inferencia no supervisada de patrones ortográficos y frecuencias de colocación léxica, lo que le permite distinguir algorítmicamente entre abreviaturas y finales de oración reales analizando el contexto adyacente. Su aplicación garantizó una segmentación precisa, manteniendo una correspondencia secuencial estricta entre las oraciones de origen y destino.

4.1.2 Alineación bilingüe semántica

El emparejamiento oracional en literatura es sumamente complejo debido a la reestructuración sintáctica de los traductores. En una primera fase del proyecto, probamos herramientas de alineación estándar como *vecalign* [57], que emplea representaciones del modelo LASER y *bertalign* [58], impulsada por los modelos mBERT y XLM-RoBERTa. Sin embargo, al aplicarlas a las particularidades léxicas del dominio, estos algoritmos se mostraron demasiado rígidos. El resultado fue una gran cantidad de segmentos mal cortados y demasiados pares de oraciones vacíos.

Bertalign utiliza un algoritmo voraz (*greedy*) muy rápido, pero prioriza casi exclusivamente los emparejamientos 1-1, lo que rompe las asimetrías de la traducción literaria. Por su parte, *vecalign* es más flexible gracias al uso de programación dinámica y ventanas deslizantes, pero su segmentación predeterminada no maneja adecuadamente las particularidades de la puntuación china. Por su parte, *vecalign* es una herramienta más flexible basada en programación dinámica, pero al ser de propósito general, requiere una segmentación externa impecable y aplica costos de salto dinámicos que no siempre se ajustan a las particularidades y al ruido de las novelas web chinas.

Ante esta situación, se desarrolló un algoritmo de alineación propio basado en el modelo LaBSE, concebido como una solución a medida para este dominio. La ventaja de este enfoque no reside en reinventar la programación dinámica, sino en su adaptación específica al corpus. En primer lugar, integra de forma nativa una limpieza de texto agresiva y una segmentación diseñada explícitamente para los caracteres de puntuación chinos y las expresiones del inglés.

En segundo lugar, acota la búsqueda evaluando de forma exhaustiva las asimetrías más comunes en el texto. Finalmente, aplica una penalización de salto que, si la similitud semántica es baja, el sistema descarta la frase de inmediato, evitando que el ruido contamine los datos.

4.1.3 Comparativa de rendimiento

Para validar el método propio, se realizó una comparativa directa frente a los otros dos algoritmos sobre capítulos de muestra, aplicando un umbral mínimo de viabilidad (similitud ≥ 0.15). La similitud se calculó mediante la similitud del coseno sobre *embeddings* de los capítulos. Esta métrica permite evaluar la proximidad semántica en un espacio multidimensional, donde un valor de 1 representa una coincidencia total y 0 una discrepancia absoluta.

Algoritmo	Frases Procesadas	Media Global	Pares Válidos	Media Filtrada
Bertalign	7795	0.6410	7237	0.6757
Vecalign	7583	0.6663	7408	0.6878
Método Propio	7506	0.7190	7440	0.7237

Táboa 4.1: Comparativa de algoritmos de alineación (Umbral de similitud ≥ 0.15)

Los resultados reflejan claramente la ventaja de adaptar el algoritmo al corpus. Aunque *bertalign* genera más frases en la fase inicial, pierde gran parte de ellas al pasar el filtro de calidad y registra la media más baja (0.6757). *Vecalign* presenta un comportamiento mucho más estable (7408 pares válidos), pero nuestra solución lo supera en ambas métricas: rescata un mayor volumen de pares útiles (7440) y alcanza la similitud media filtrada más alta (0.7237).

Al unificar la limpieza previa, una segmentación específica por idioma y una penalización de salto, este método consigue el mejor equilibrio entre aprovechar la mayor cantidad de datos posible y garantizar una mejor calidad final del material de entrenamiento.

Caso de ejemplo

Para ilustrar las diferencias más notables, se ha seleccionado un caso específico de ejemplo. Este caso ilustra un problema común en las pruebas realizadas: las adaptaciones de estilo del traductor. En este texto, el traductor al inglés toma dos decisiones clave. Por un lado, en chino el autor utiliza la descripción “中年修士” (monje/cultivador de mediana edad). El traductor decide cambiarlo por su nombre propio explícito (“Li Qinghou”) o por el pronombre (“he”) para hacer la lectura más natural en inglés. Por otro, el traductor altera el orden de las acotaciones (quién dice qué) y divide las respuestas.

Estas decisiones rompen la equivalencia literal, confundiendo a los sistemas de alineación automáticos. Para facilitar el análisis, se han etiquetado las oraciones con números del (1) al (6).

Texto Original (Chino):

中年修士看着白小纯，半晌无语。(1) “既然你这么害怕，为什么还要强行去点香十多次？”
(2) 中年修士缓缓开口。(3)
“我怕死啊 (4)，修仙不是能长生么，我想长生啊。” (5) 白小纯委屈的说道。(6)

Texto Original (Inglés):

Li Qinghou looked silently at Bai Xiaochun. (1) “If you were so scared, then why did you light it over ten times?” (2) he asked.
(3)
“'Cuz I'm scared of dying!” (4) Bai Xiaochun replied indignantly.
(6) “Isn't the point of immortal cultivation to be able to live forever? I want to live forever!” (5)

Bertalign:

白小纯可怜兮兮的说道。(0) ; Li Qinghou looked silently at Bai Xiaochun. (1)

中年修士看着白小纯，半晌无语。(1) ; --- (0)

“既然你这么害怕，为什么还要强行去点香十多次？” (2) ; “If you were so scared, then why did you light it over ten times?” (2) he asked.
(3) “'Cuz I'm scared of dying!” (4)

中年修士缓缓开口。(3) ; Bai Xiaochun replied indignantly. (6)

“我怕死啊，修仙不是能长生么，我想长生啊。” (4,5) ; “Isn't the point of immortal cultivation to be able to live forever? I want to live forever!” (5)

白小纯委屈的说道。(6) ; Li Qinghou was once again struck speechless.
(0)

En este caso Bertalign sufre un colapso al no ser capaz de mapear semánticamente la descripción del personaje con el nombre propio, y arrastra un desfase desde oraciones previas (0). Agrupa erróneamente un diálogo de Li Qinghou y uno de Bai Xiaochun en un solo bloque

en inglés (2, 3, 4). Además, confunde a los emisores, emparejando la acción del monje (3) con la de Bai Xiaochun (6).

Vecalign:

中年修士看着白小纯，半晌无语。(1) ; Li Qinghou looked silently at Bai Xiaochun. (1)

“既然你这么害怕，为什么还要强行去点香十多次？”(2) 中年修士缓缓开口。(3) ; “If you were so scared, then why did you light it over ten times?” (2) he asked. (3)

“我怕死啊 (4)，修仙不是能长生么，我想长生啊。”(5) ; “'Cuz I'm scared of dying!” (4) Bai Xiaochun replied indignantly. (6)

白小纯委屈的说道。(6) ; “Isn't the point of immortal cultivation to be able to live forever? I want to live forever!” (5)

Como Vecalign es un algoritmo de alineación monotónica que combina similitud semántica (basada en embeddings multilingües) con restricciones estrictas de orden, no permite cruces ni reordenamientos. Cuando se encuentra con una inversión en la traducción (el segmento 6 aparece antes que el 5 en inglés), no puede alinear cada oración con su correspondiente exacta. En su lugar, intenta maximizar la similitud total respetando la monotonicidad, lo que lo lleva a agrupar segmentos: el bloque chino (4,5) se alinea con (4,6) en inglés, y el segmento restante chino (6) se empareja con (5).

Modelo Propio:

中年修士看着白小纯，半晌无语。(1) ; Li Qinghou looked silently at Bai Xiaochun. (1)

既然你这么害怕，为什么还要强行去点香十多次？(2) ; If you were so scared, then why did you light it over ten times? (2)

中年修士缓缓开口。(3) ; he asked. (3)

我怕死啊 (4)，修仙不是能长生么，我想长生啊。(5) ; 'Cuz I'm scared of dying! (4)

白小纯委屈的说道。(6) ; Bai Xiaochun replied indignantly. (6)

En este caso, el sistema acierta en gran medida al trazar la equivalencia semántica directa

(identificando “Li Qinghou” y “he” con la descripción), lo que le permite aislar correctamente las acotaciones (1, 3 y 6) de los diálogos sin heredar desfases. Sin embargo, también comete un error: debido a la reestructuración del traductor, el modelo Propio pierde la segunda parte del diálogo en inglés (5) (“*Isn’t the point of immortal cultivation...*”). Aunque empareja bien la parte inicial (4), el reordenamiento de la frase (6) provocó que se modelo ignorara u omitiera el fragmento final de la traducción.

Aunque este caso representa solo una muestra específica seleccionada para ilustrar las diferencias entre los distintos sistemas, resulta representativa de la tendencia observada en el resto de casos que suponen una dificultad para los sistemas de segmentación. Tal y como se muestra en la Tabla 4.1, la evaluación sobre la totalidad del corpus confirma que el método propuesto logra superar a las alternativas, aunque en general muestran resultados similares.

4.2 Filtrado de datos

La investigación en adaptación al dominio ha demostrado que, al entrenar modelos neuronales de traducción, el rendimiento del modelo no escala de manera lineal con el volumen bruto del texto [59]. Por el contrario, un *dataset* contaminado con muestras triviales o ruidosas genere gradientes poco informativos que degradan los pesos de la red, provocando un estancamiento en la curva de pérdida de validación. En este contexto de especialización lingüística para los géneros *wuxia* y *xianxia*, la calidad de las oraciones resulta un factor más determinante que el volumen total del corpus.

Por consiguiente, previo a la ingesta de datos por parte de los modelos *Transformers* y LLMs (y tras la alineación descrita anteriormente), se incluyó un proceso de reducción del conjunto de entrenamiento. El objetivo principal fue descartar pares bilingües irrelevantes y seleccionar exclusivamente muestras que maximizaran la ganancia de información durante las fases de *fine-tuning*, así como optimizar estos mismos procesos.

Para ejecutar esta depuración, se adoptó el marco teórico propuesto por Zhang et al. [60] en su estudio sobre conjuntos de prueba conscientes de la varianza (*Variance-Aware Machine Translation Test Sets*). El fundamento lógico dicta que las muestras que no generan variabilidad en sus puntuaciones de traducción resultan inútiles o desfavorables para guiar al modelo. Dicho de otro modo: si una frase es extremadamente fácil todos los modelos la traducen a la perfección, y si es demasiado compleja ningún modelo acierta, de forma que no aporta información útil para el entrenamiento.

El cálculo de esta varianza requiere la intervención de un algoritmo de evaluación de traducción. Tradicionalmente, el estándar es la métrica BLEU o METEOR. Sin embargo, se decidió optar por el uso de la métrica CHRF para el filtrado.

En la práctica, las tres métricas tienden a tener un comportamiento estadístico similar, es decir, si la puntuación baja en un modelo respecto a otro, las tres métricas suelen reflejar esa misma caída de forma correlacionada. Por ende, la elección de la métrica no alteraría de manera drástica la distribución subyacente. Sin embargo, METEOR fue descartada porque su ejecución habría tardado demasiado tiempo para un volumen de datos tan grande, y BLEU fue excluida por penalizar excesivamente las variaciones morfológicas al exigir coincidencias exactas a nivel de palabra. En su lugar, se optó por CHRF, que evalúa las coincidencias mediante *n-gramas* de caracteres en lugar de palabras completas, empleando una fórmula estadística (*F-score*) que equilibra la precisión y la sensibilidad (*recall*). Para el dominio literario, CHRF garantiza que una frase que comparte raíces de significado, pero difiere en el orden de palabras, no sea clasificada como ruido.

Implementando este marco, a través de varios modelos de arquitectura *seq2seq*, se realizaron evaluaciones sobre el corpus. Para cada muestra, se calculó la puntuación media y la varianza utilizando la métrica CHRF.

Los resultado permitieron clasificar las muestras resultantes en tres estratos de dificultad de aprendizaje:

1. Muestras fáciles (Baja varianza, alta media): Emparejamientos triviales, traducciones cortas y conectores lógicos comunes.
2. Muestras difíciles (Baja varianza, baja media): Segmentos donde el traductor humano alteró por completo el hilo narrativo original, errores de segmentación residuales o modismos que carecen de equivalencia funcional.
3. Muestras intermedias (Alta varianza): El estrato con más utilidad. Son emparejamientos donde la métrica fluctúa de forma dramática, oraciones que exigen un conocimiento cultural específico pero que mantienen una estructura lógica descifrable.

Para evitar sesgos y asegurar que la red se enfrente a una distribución probabilística equilibrada, se realizó un muestreo uniforme sobre esta clasificación. Se extrajeron casos abarcando un tercio de cada uno de los tres grupos.

De este modo, a partir de un corpus que constaba originalmente de alrededor de 500.000 segmentos alineados, la reducción extrajo exactamente 100.000 casos de alta densidad semán-

tica. Este subconjunto final acorta los tiempos de cómputo a la vez que garantiza que los modelos consuman datos de calidad.

4.3 Análisis del corpus

Una vez concluidas las fases de limpieza, segmentación y alineación bilingüe, los datos resultantes se consolidaron en un corpus unificado. Tras aplicar el filtrado por varianza descrito en la sección anterior, el conjunto de datos se dividió de forma aleatoria en tres particiones estándar para el aprendizaje automático: entrenamiento, validación y test.

Para comprender los datos con los que se está trabajando y validar el impacto del filtrado selectivo, se llevó a cabo un análisis lexicométrico del corpus. Para la correcta interpretación de estos resultados, es preciso definir brevemente las métricas cuantitativas evaluadas [61]:

En primer lugar, los *tokens* representan el número total de palabras concurrentes en el texto, mientras que los *types* contabilizan el número de palabras únicas. A partir de estos valores se extrae el *Type-Token Ratio* (TTR), que es el ratio directo entre ambos y mide la riqueza básica del vocabulario. Dado que el TTR tiende a disminuir artificialmente a medida que el texto se alarga, se implementa el *Standardized TTR* (STTR), el cual calcula el TTR en bloques de tamaño fijo (1.000 palabras) y promedia los resultados.

Otras medidas de corrección estadística incluyen el *Índice Guiraud* (R), que divide los *types* entre la raíz cuadrada de los *tokens* ($V / \sqrt{N}$), y la métrica *Measure of Textual Lexical Diversity* (MTLD), que evalúa la longitud media de las secuencias que logran mantener un valor TTR por encima de un umbral determinado. Finalmente, se analiza la *Densidad Léxica*, que mide la proporción de palabras con carga semántica pura (excluyendo elementos funcionales), y los *Hapax Legomena*, que son aquellos términos que aparecen exactamente una sola vez en el corpus, indicando la presencia de vocabulario altamente especializado.

En la siguiente tabla se comparan las estadísticas del corpus inicial frente a las del conjunto de datos definido tras el filtrado.

El análisis descriptivo de estas métricas revela aspectos fundamentales sobre las características intrínsecas de los textos *wuxia* y *xianxia*. En primer lugar, se observa una asimetría estructural entre ambos idiomas: el texto origen en chino presenta una cantidad de formas únicas (*types*) y un índice de diversidad léxica marcadamente superior al inglés en todos los escenarios. Esta diferencia responde, fundamentalmente, a las diferencias morfológicas y tipológicas entre ambas lenguas. El texto origen posee una alta densidad de terminología es-

pecífica construida mediante la composición de caracteres, cuya transliteración o adaptación al inglés altera de forma natural los patrones de frecuencia y distribución léxica.

Un punto relevante de este análisis reside en el impacto del filtrado algorítmico. Aunque la reducción de datos basada en la varianza eliminó más del 60% del volumen total de palabras (pasando de 9,3 a 3,6 millones de *tokens* en inglés), la riqueza del vocabulario se preservó correctamente, logrando retener más de 23.600 *types* de los 28.500 originales.

Aún más significativo es el incremento generalizado de los indicadores de diversidad léxica en el corpus filtrado. El índice TTR estandarizado (STTR), y la métrica MTLT (*Measure of Textual Lexical Diversity*), aumentaron notablemente en ambos idiomas. Adicionalmente, la proporción de *Hapax Legomena* creció de forma considerable, lo que indica una mayor concentración de terminología atípica.

Esta evolución estadística demuestra la eficacia del enfoque de muestreo basado en la varianza (*variance-aware*): al descartar el ruido y los segmentos triviales, se consigue aislar y preservar la complejidad lingüística inherente a las obras, proporcionando un corpus adecuado para la posterior fase de adaptación al dominio.

Métrica	Inglés (Bruto)	Chino (Bruto)	Inglés (Filtrado)	Chino (Filtrado)
Total <i>Tokens</i>	9.351.283	6.938.915	3.687.379	2.741.077
Total <i>Types</i>	28.500	133.374	23.657	95.208
TTR Clásico	0,30%	1,92%	0,64%	3,47%
STTR (Bloques 1k)	39,97%	53,53%	51,62%	67,43%
Índice Guiraud (R)	9,32	50,63	12,32	57,51
MTLD	91,25	168,60	178,98	590,60
Densidad Léxica	63,81%	57,58%	59,85%	60,06%
<i>Hapax Legomena</i>	18,11%	33,57%	21,66%	38,81%

Táboa 4.2: Análisis lexicométrico: Comparativa del corpus bruto vs. filtrado

Enfoques estadísticos de traducción

LA traducción automática ha experimentado un desarrollo continuo desde sus primeras conceptualizaciones a mediados del siglo XX. Antes de la adopción generalizada de las redes neuronales profundas en el procesamiento del lenguaje natural, el modelo de referencia en la investigación y la industria fue la Traducción Automática Estadística (SMT, por sus siglas en inglés) [62].

Este enfoque, fundamentado en la teoría de la información de Claude Shannon [63] y anticipado por el memorando de Warren Weaver en 1949 [7], representó una alternativa directa a los sistemas tradicionales de traducción basados en reglas (RBMT). Mientras que la arquitectura RBMT dependía de diccionarios estáticos y de la codificación manual de reglas gramaticales por parte de lingüistas, una metodología con severas limitaciones de escalabilidad y escasa tolerancia a la ambigüedad inherente al lenguaje natural, la SMT reformuló la tarea de traducción como un problema de decodificación probabilística sustentado en la extracción de patrones a partir de datos bilingües.

En el núcleo teórico de la traducción automática estadística se encuentra el modelo del canal ruidoso (*noisy channel model*). Según esta formulación matemática, se presenta teóricamente que una oración observada en el idioma origen (por ejemplo, el chino mandarín) es, en realidad, una oración en el idioma destino (el inglés) que ha sido “distorsionada” al pasar por un canal de comunicación ruidoso. El objetivo del sistema de traducción es, por tanto, recuperar la oración original no distorsionada en inglés e dada la oración observada en el idioma extranjero f . Matemáticamente, este proceso de decodificación se expresa mediante la aplicación de la regla de Bayes para encontrar la traducción más probable e^* :

$$e^* = \arg \max_e p(e|f) = \arg \max_e \frac{p(f|e)p(e)}{p(f)}$$

Dado que el denominador $p(f)$ es constante para una oración extranjera dada y no afec-

ta al proceso de maximización, la ecuación se simplifica a la búsqueda del argumento que maximiza el producto del numerador:

$$e^* = \arg \max_e p(f|e)p(e)$$

Esta formulación matemática divide el proceso de traducción en dos submodelos independientes, optimizados con conjuntos de datos distintos. Por una parte, el Modelo de Lenguaje, $p(e)$, garantiza la fluidez y la corrección gramatical de la hipótesis generada en el idioma de destino. Su estimación se realiza habitualmente mediante cadenas de Markov aplicadas sobre grandes corpus monolingües para calcular las probabilidades espaciales de los n -gramas. Por otra parte, el Modelo de Traducción, $p(f|e)$, evalúa la fidelidad semántica translingüística, determinando la probabilidad de que la secuencia extranjera observada sea una traducción válida de la oración generada en inglés. Este último componente se parametriza a partir del análisis estadístico de frecuencias en corpus paralelos alineados, consolidando el paradigma de aprendizaje automático guiado por datos en el procesamiento de lenguajes naturales.

5.1 Fundamentos probabilísticos

Durante la década de 1990, investigadores del centro Thomas J. Watson de IBM formalizaron una serie de modelos estadísticos secuenciales, conocidos en la literatura como los Modelos IBM, con el propósito de estimar el modelo de traducción $p(f|e)$ a partir de textos paralelos [9]. La dificultad técnica fundamental de este proceso reside en la naturaleza de los datos de entrenamiento: los corpus bilingües proporcionan equivalencias a nivel oracional, pero carecen de anotaciones previas sobre el alineamiento léxico. En consecuencia, el sistema debe inferir probabilísticamente qué término exacto de la oración de origen se vincula con qué término de la oración de destino.

Para resolver esta carencia de supervisión directa, se introdujo el concepto de alineación (*alignment*). La alineación actúa como una variable latente que mapea cada posición en el idioma origen con su contraparte generadora en el idioma destino [62]. Los modelos estadísticos puros calculan la probabilidad léxica aislada de que una palabra en otro idioma sea la traducción correcta, apoyándose posteriormente en modelos de distorsión posicional simples para intentar predecir los cambios en el orden sintáctico de la frase.

Para ilustrar empíricamente el funcionamiento de estos modelos iniciales y evidenciar sus limitaciones estructurales, se presenta un caso práctico extraído de la fase de experimentación del corpus de este trabajo. Considérese la siguiente oración de origen en chino y su correspondiente traducción humana de referencia:

- **Origen (Chino):** 刚想到这里，陆畏因眼前忽然一黑
- **Referencia Humana:** While thinking of this, Lu Wei Yin's vision suddenly turned dark

Al procesar esta secuencia mediante una implementación del Modelo 2 de IBM, entrenada específicamente sobre el corpus del proyecto, el sistema decodifica la oración maximizando la probabilidad de traducción a nivel de palabra junto con su probabilidad de alineamiento absoluto. La salida generada por el decodificador es la siguiente:

- **Traducción SMT:** just thought here and lu because front suddenly vision

Este resultado se construye ensamblando de manera secuencial los vocablos que presentan la mayor probabilidad de traducción léxica aislada para cada carácter o bloque corto de caracteres observados en el original. Internamente, el modelo estocástico justifica su decisión algorítmica basándose en las siguientes probabilidades de correspondencia ($t(e|f)$) directa extraídas durante su entrenamiento: *just* (34,01 %), *thought* (36,66 %), *here* (31,93 %), *and* (24,51 %), *lu* (50,24 %), *because* (37,01 %), *front* (27,77 %), *suddenly* (65,14 %) y *vision* (26,61 %).

Como demuestra este caso, aunque el sistema logra identificar correctamente el vocabulario principal, mapeando entidades (*lu*), conectores lógicos (*and*, *because*) y descriptores espaciotemporales o perceptivos (*thought*, *front*, *suddenly*, *vision*), es incapaz de articular una oración sintácticamente funcional. A pesar de asentar históricamente la viabilidad de la traducción impulsada por datos, la SMT basada en palabras presenta una limitación inherente: la ausencia total de modelado contextual.

Al forzar al algoritmo a computar correspondencias léxicas de forma aislada y aproximar el reordenamiento sintáctico mediante funciones de distancia simples, el sistema carece de mecanismos para procesar dependencias a largo plazo, modismos o reglas gramaticales básicas. Esta deficiencia produce resultados inconexos y desestructurados, un problema que se acentúa notablemente al operar entre lenguas con divergencias tipológicas tan marcadas como el chino mandarín y el inglés.

5.2 Traducción Basada en Frases

Como respuesta a las limitaciones del enfoque basado en palabras, la investigación en traducción automática derivó hacia la Traducción Automática Estadística Basada en Frases (PBMT, por sus siglas en inglés) [64]. Este modelo trasladó la unidad operativa básica desde la

palabra individual hacia secuencias contiguas, denominadas “frases” (entendidas estadísticamente como n -gramas, sin requerir correspondencia con constituyentes sintácticos formales).

Al procesar bloques de palabras de forma conjunta, la PBMT lograba asimilar el contexto local, lo que permitía resolver ambigüedades léxicas inmediatas, gestionar problemas de concordancia y facilitar el reordenamiento sintáctico a corto plazo. De este modo, las expresiones idiomáticas o las estructuras complejas que carecían de sentido mediante una traducción literal podían procesarse y recuperarse de la tabla de traducción como entidades semánticas cohesionadas.

Dentro del ecosistema de investigación de la época coexistieron diversos motores de decodificación. Mientras que plataformas como *Joshua* o *cdec* exploraron variantes jerárquicas y basadas en sintaxis, la implementación de referencia más influyente para el paradigma PBMT secuencial fue *Moses*, un *toolkit* de código abierto desarrollado por Philipp Koehn y colaboradores en 2007 [65] (sustituyendo a su predecesor directo, *Pharaoh*). Esta herramienta proporcionó una infraestructura estandarizada que abarcaba desde el preprocesamiento y la alineación bidireccional, mediante el uso de GIZA++ y heurísticas de simetrización, hasta la extracción de frases y la decodificación avanzada.

Desde una perspectiva matemática, Moses adoptó un marco log-lineal. En lugar de limitarse a la formulación multiplicativa estricta del modelo del canal ruidoso, el sistema calcula la hipótesis óptima mediante una combinación lineal de múltiples funciones de características (*feature functions*), $h_i(e, f)$, ponderadas por coeficientes λ_i :

$$e^* = \arg \max_e \sum_i \lambda_i h_i(e, f)$$

Estos pesos λ_i se optimizaban habitualmente utilizando técnicas de ajuste discriminativo frente a métricas de evaluación automatizadas, como el algoritmo MERT (*Minimum Error Rate Training*).

Durante el proceso de decodificación, ejecutado mediante un algoritmo de búsqueda heurística (*beam search*), Moses evalúa el espacio de hipótesis integrando un conjunto robusto de características. Estas incluyen las probabilidades de traducción de frases en ambas direcciones, $\phi(f|e)$ y $\phi(e|f)$, pesos léxicos bidireccionales, que actúan como mecanismo de suavizado para penalizar frases cuyas palabras no presentan un buen alineamiento individual, un modelo de lenguaje en el idioma de destino (típicamente de n -gramas) para garantizar la corrección gramatical, y un modelo de reordenamiento léxico. Este último calcula la distribución de

probabilidad de que una frase mantenga un orden monótono, se invierta respecto a la frase anterior o se disloque de forma discontinua.

5.2.1 El fracaso de PBMT en la Traducción literaria Especializada

Si bien Moses se consolidó como el marco de referencia de la traducción académica e industrial durante casi una década, su base teórica seguía anclada a la coincidencia discreta de formas superficiales y al recuento empírico de frecuencias. Paralelamente, esta arquitectura presentaba graves cuellos de botella computacionales. El rendimiento de la PBMT dependía de la extracción y el almacenamiento en memoria RAM de tablas de frases masivas y modelos de lenguaje probabilísticos. A medida que los corpus de entrenamiento crecían, la huella de memoria escalaba de forma exponencial, encareciendo y ralentizando drásticamente tanto la fase de entrenamiento como la decodificación en tiempo real [44]. Además de esta ineficiencia algorítmica, al aplicar estos sistemas a la traducción literaria, sus limitaciones cualitativas se hicieron innegables [41].

La literatura fantástica china presenta una alta densidad léxica, un uso recurrente de estructuras idiomáticas de cuatro caracteres (*chengyu*) y una terminología hiperespecializada vinculada a conceptos taoístas o marciales. En este dominio, los modelos estadísticos sufren un problema crítico de dispersión de datos [28]. Si una secuencia léxica o una combinación exacta de adjetivo y sustantivo no figuraba de forma idéntica en el corpus de entrenamiento, el decodificador fragmentaba la estructura y recurría al *back-off*, degradando la salida a una traducción literal basada en palabras aisladas. Este comportamiento, ampliamente documentado en la evaluación de SMT sobre textos literarios, generaba resultados sintácticamente incoherentes, alteraba la cohesión discursiva y neutralizaba por completo el registro narrativo original.

En consecuencia, el procesamiento bilingüe de este tipo de literatura evidenció la necesidad de un modelo que superase tanto las restricciones de las unidades simbólicas discretas como la insostenible escalabilidad de las tablas de frases estáticas. Resultaba indispensable una arquitectura capaz de aprender representaciones continuas y distribuidas del lenguaje, permitiendo generalizar la información semántica a partir del contexto global en lugar de depender de la memorización exacta de n -gramas. Esta doble carencia impulsó la transición definitiva hacia la Traducción Automática Neuronal (NMT), cuyo funcionamiento y aplicación se detallan en el siguiente capítulo.

Traducción Automática Neuronal

LA consolidación del aprendizaje profundo (*Deep Learning*) supuso el desuso de los métodos estadísticos y estableció la Traducción Automática Neuronal (NMT) como el nuevo estado del arte en el procesamiento bilingüe [66]. A diferencia de los sistemas basados en frases, que operaban fragmentando el texto en unidades simbólicas discretas e independientes, las arquitecturas NMT procesan la información mediante representaciones vectoriales densas y continuas (*embeddings*).

Bajo este paradigma, el procesamiento se realiza de extremo a extremo (*end-to-end*). El sistema proyecta la oración origen completa en un espacio semántico latente de alta dimensionalidad para, a partir de dicho contexto matemático, decodificar la traducción correspondiente [67].

Para fundamentar la elección de los modelos de referencia (*baselines*) empleados en la fase de experimentación de este trabajo, resulta metodológicamente necesario analizar la evolución de estas arquitecturas. En consecuencia, este capítulo describe el desarrollo algorítmico de la NMT: desde los modelos iniciales de Secuencia a Secuencia (Seq2Seq) basados en Redes Neuronales Recurrentes (RNN), pasando por la integración crucial de los mecanismos de atención [68], hasta culminar en la arquitectura *Transformer*, la cual constituye el núcleo computacional de los Grandes Modelos de Lenguaje contemporáneos.

6.1 El paradigma Sequence-to-Sequence

Las primeras arquitecturas eficaces de Traducción Automática Neuronal sustituyeron el alineamiento de unidades léxicas por un modelo de traducción continuo denominado *Sequence-to-Sequence*. Este modelo se fundamentó inicialmente en el uso de RNN, diseñadas para procesar datos secuenciales donde la longitud de la entrada difiere de la longitud de la salida, una

característica estructural indispensable para gestionar la asimetría entre idiomas topológicamente distintos.

El diseño clásico de Seq2Seq se articula en dos módulos neuronales acoplados que operan de manera secuencial: el codificador (*encoder*) y el decodificador (*decoder*).

- El codificador: Su función es procesar la oración de origen de forma secuencial. Dada una secuencia de entrada $x = (x_1, x_2, \dots, x_T)$, en cada paso temporal t , la red recurrente actualiza su estado oculto (*hidden state*) h_t a partir de la palabra actual x_t y el estado oculto del paso temporal anterior h_{t-1} . Matemáticamente, esta actualización se expresa mediante una función de activación no lineal f :

$$h_t = f(h_{t-1}, x_t)$$

El objetivo algorítmico del codificador es asimilar la oración completa e integrar su información semántica y sintáctica en el último estado oculto, h_T . A este vector resultante se le denomina vector de contexto c , el cual constituye una representación densa de dimensionalidad fija de todo el texto de entrada.

- El decodificador: Una vez que el codificador concluye su fase de lectura, transfiere el vector de contexto c al decodificador. Este módulo, compuesto por otra red recurrente, inicializa su estado oculto s_0 con dicho vector condensado para generar la secuencia equivalente en el idioma destino $y = (y_1, y_2, \dots, y_{T'})$. Este proceso de generación es autorregresivo; el modelo predice la probabilidad de la siguiente palabra y_t condicionada al vector de contexto c , al estado oculto actual s_t y a todos los *tokens* generados previamente:

$$p(y_t | y_1, \dots, y_{t-1}, x) = g(y_{t-1}, s_t, c)$$

El proceso iterativo concluye cuando el decodificador emite un *token* especial que indica el final de la oración (EOS, por *End of Sentence*).

El cuello de botella del contexto y las redes LSTM

Aunque el paradigma Seq2Seq representó un avance significativo frente a los sistemas estadísticos, su implementación inicial mediante redes RNN estándar presentaba dos limitaciones estructurales críticas.

La primera limitación radicaba en la dificultad para optimizar dependencias a largo plazo, un fenómeno conocido como el problema del desvanecimiento del gradiente. A medida que la longitud de las oraciones aumenta las multiplicaciones matriciales iterativas durante

el algoritmo de retropropagación a través del tiempo (BPTT) provocan que la señal de error tienda a cero. En consecuencia, el codificador pierde la capacidad de retener la información de los primeros *tokens* al concluir el procesamiento de la oración.

Para mitigar este problema, la investigación adoptó arquitecturas más complejas como *Long Short-Term Memory* (LSTM) y *Gated Recurrent Unit* (GRU). Las unidades LSTM introdujeron el concepto de “célula de memoria”, regulada mediante compuertas lógicas (de olvido, entrada y salida). Estos mecanismos permiten a la red determinar algorítmicamente qué información pasada debe conservarse y qué datos irrelevantes deben descartarse, estabilizando los gradientes y ampliando el rango temporal operativo de la red.

La segunda limitación, sin embargo, era inherente al propio diseño arquitectónico: el cuello de botella del vector de contexto. Exigir a una red neuronal que comprima el significado global de una oración extensa en un único vector matemático c de dimensión fija resultaba computacionalmente ineficiente. Esta restricción representacional provocaba una degradación severa en el rendimiento del modelo al traducir secuencias superiores a 30 o 40 palabras, un límite estructural que las arquitecturas LSTM aliviaban, pero no lograban resolver de manera definitiva [69, 70].

6.2 Mecanismos de Atención

Para resolver la limitación estructural del vector de contexto de dimensión fija, la arquitectura *Sequence-to-Sequence* evolucionó mediante la integración de mecanismos de atención (*Attention Mechanisms*). Este enfoque exime al modelo de la necesidad de comprimir toda la información en una única representación estática. En su lugar, permite al decodificador acceder dinámicamente a las distintas partes de la oración de origen durante cada paso temporal del proceso de generación.

Bajo este paradigma, el codificador conserva el conjunto completo de los estados ocultos intermedios $(h_1, h_2, \dots, h_T)$ correspondientes a cada elemento de la secuencia de entrada. Cuando el decodificador requiere generar un nuevo *token*, calcula un vector de contexto dinámico c_t específico para ese instante, computado como la suma ponderada de todos los estados del codificador. A través de este proceso, el modelo aprende a asignar coeficientes de atención más elevados a las representaciones del idioma origen que poseen mayor relevancia para la palabra que se está decodificando.

El desarrollo de estos mecanismos en la NMT se consolidó fundamentalmente en torno a

dos formulaciones: la atención aditiva y la atención multiplicativa.

6.2.1 Atención Aditiva (Bahdanau)

Propuesto por Dzmitry Bahdanau et al. [70], este mecanismo fue pionero en la resolución del cuello de botella representacional en NMT. La característica arquitectónica que define al modelo de Bahdanau es que, para calcular los pesos de atención en el paso temporal t , el sistema emplea el estado oculto inmediatamente anterior del decodificador, s_{t-1} .

La puntuación de alineamiento $e_{t,i}$, que cuantifica el grado de correspondencia entre el estado a generar y el estado oculto del codificador h_i , se calcula mediante una red neuronal *feed-forward* de una sola capa oculta:

$$e_{t,i} = v_a^T \tanh(W_a s_{t-1} + U_a h_i)$$

Estas puntuaciones no normalizadas se procesan mediante una función *softmax* para obtener una distribución de probabilidades $\alpha_{t,i}$ cuya suma es igual a 1. Finalmente, el vector de contexto dinámico c_t se ensambla calculando la suma ponderada de los estados del codificador basada en estas probabilidades. Esta formulación permitió al modelo aprender alineamientos suaves entre los idiomas de forma conjunta con la traducción, mitigando el problema de las secuencias largas.

6.2.2 Atención Multiplicativa (Luong)

Posteriormente, Minh-Thang Luong et al. [68] propusieron una variante arquitectónica diseñada para simplificar el cálculo de los alineamientos y mejorar la eficiencia computacional, conocida como atención multiplicativa o basada en el producto escalar.

A diferencia del enfoque de Bahdanau, la arquitectura de Luong modifica el flujo de dependencias: primero ejecuta la actualización del decodificador para obtener su estado oculto actual s_t , y es este estado el que se utiliza como vector de consulta para evaluar los estados del codificador. Además, para calcular la similitud entre la consulta del decodificador y las claves del codificador, este modelo prescinde de la red neuronal prealimentada y emplea un cálculo directo de producto escalar, parametrizado mediante una matriz de pesos W (variante conocida como *General Attention*):

$$e_{t,i} = s_t^T W h_i$$

Al reducir las operaciones a multiplicaciones matriciales estandarizadas, la arquitectura de Luong disminuyó los tiempos de entrenamiento y sentó el precedente matemático para las

arquitecturas contemporáneas basadas íntegramente en mecanismos de autoatención.

6.3 La arquitectura Transformer

A pesar de que la inclusión de los mecanismos de atención dotó a los modelos Seq2Seq de la capacidad para procesar dependencias a largo plazo, su núcleo operativo continuaba anclado a las RNN. La naturaleza estrictamente secuencial de las RNN exige que el cálculo del estado oculto en la posición t dependa de la finalización del paso $t - 1$. Esta restricción impedía la paralelización del entrenamiento a nivel de oración, constituyendo un cuello de botella computacional para el escalado de los modelos.

Esta limitación fue resuelta estructuralmente con la publicación de la arquitectura *Transformer* [10]. Este modelo prescindió por completo de las capas recurrentes y convolucionales, fundamentando el procesamiento de secuencias exclusivamente en mecanismos de atención. Al eliminar la recurrencia, el *Transformer* permite procesar la totalidad de los *tokens* de entrada de manera simultánea, posibilitando un entrenamiento paralelo sobre billones de palabras.

6.3.1 Autoatención y atención multicabezal

Para modelar las dependencias sin recurrir a una memoria direccional, la arquitectura introdujo el mecanismo de auto-atención (*Self-Attention*). Mediante este cálculo, cada elemento de una secuencia evalúa su relación matemática con el resto de los elementos de la misma secuencia, independientemente de su distancia posicional.

A nivel técnico, la auto-atención proyecta linealmente cada *embedding* de entrada en tres vectores: Consulta (*Query* - Q), Clave (*Key* - K) y Valor (*Value* - V). La atención se calcula computando el producto escalar entre las consultas y las claves, escalando el resultado por la raíz cuadrada de la dimensión de las claves ($\sqrt{d_k}$) para estabilizar los gradientes. Posteriormente, se aplica una función *softmax* para obtener los pesos normalizados, los cuales ponderan la matriz de Valores:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Para enriquecer este proceso, el modelo implementa la atención multicabezal (*Multi-Head Attention*). En lugar de ejecutar una única función de atención, el cálculo se divide en múltiples “cabezales” proyectados en paralelo. Esto permite al modelo aprender dependencias conjuntas desde distintos subespacios de representación. En el contexto de la literatura wuxia, un cabezal podría especializarse en rastrear la jerarquía relacional entre personajes (*shixiong* y

shidi), mientras otro cabezal independiente se enfoca en resolver la temporalidad de la acción marcial descrita.

6.3.2 Codificación posicional y atención cruzada

Dado que la matriz de auto-atención procesa todo a la vez, el modelo es innatamente ciego al orden de las palabras. No distingue entre “el maestro golpea al discípulo” y “el discípulo golpea al maestro”. Para subsanarlo, el Transformer incorpora vectores de *Positional Encoding* que se suman a los *embeddings*. Mediante el uso de funciones sinusoidales y cosenoidales de distintas frecuencias, se codifica la posición absoluta y relativa de cada *token* en el espacio.

A nivel estructural, el Transformer mantiene la división operativa en dos bloques acoplados:

- El bloque codificador (generalmente compuesto por una pila de 6 a 12 capas con normalización y redes *feed-forward*) procesa la secuencia de origen en su totalidad para generar representaciones vectoriales enriquecidas contextualmente.
- El bloque decodificador opera de forma autorregresiva (generando palabra por palabra). Incorpora una subcapa fundamental conocida como *Cross-Attention*. Aquí, las matrices de Consulta (Q) se derivan del estado actual del decodificador, mientras que las Claves (K) y los Valores (V) provienen íntegramente de la representación final emitida por el codificador. De esta forma se garantiza que el proceso de predicción léxica dependa de forma estricta de la información semántica extraída del texto fuente.

6.4 Segmentación de subpalabras

El procesamiento de secuencias en arquitecturas neuronales exige transformar el texto de entrada en representaciones discretas manejables por el modelo. En los sistemas de traducción estadística, esta segmentación se realizaba habitualmente a nivel de palabra completa. Sin embargo, al procesar lenguas tipológicamente distantes como el chino y el inglés, o al traducir textos literarios con una alta densidad de neologismos, este enfoque genera un alto volumen de palabras fuera de vocabulario (OOV, por sus siglas en inglés), las cuales el sistema sustituye por el *token* de error [UNK].

Para solucionar este problema de dispersión sin incrementar excesivamente la dimensionalidad de la matriz de *embeddings*, la NMT emplea algoritmos estadísticos de segmentación de subpalabras [71]. Estos métodos modelan los caracteres y secuencias frecuentes como unidades unificadas, mientras que desglosan las palabras infrecuentes en fragmentos menores,

sílabas o bytes.

Las arquitecturas evaluadas en este trabajo utilizan algoritmos como *SentencePiece* y *Byte-Pair Encoding* (BPE). A diferencia de otras herramientas, *SentencePiece* procesa el texto como un flujo continuo, asimilando los espacios como parte del alfabeto (mediante el símbolo `_`). Esta propiedad lo hace agnóstico al idioma y elimina la dependencia de diccionarios de pre-segmentación [72]. Asimismo, la integración de mecanismos *byte-fallback* garantiza que los caracteres no presentes en el vocabulario base se codifiquen directamente en formato UTF-8, asegurando una cobertura total sobre el texto de origen.

6.5 Selección de modelos

La fase experimental de este trabajo se basa en la implementación de cinco arquitecturas Transformer representativas del estado del arte. Debido a la enorme cantidad de datos paralelos y a los costes computacionales que exige inicializar y entrenar estos modelos desde cero con pesos aleatorios, la metodología adoptada sigue el paradigma actual del Procesamiento del Lenguaje Natural, el aprendizaje por transferencia (*Transfer Learning*). En concreto, se aplica un ajuste fino sobre sistemas preentrenados para adaptarlos al dominio específico de la literatura fantástica china.

Con el objetivo de garantizar una comparativa justa, todos los modelos se han entrenado bajo las mismas restricciones de entorno, empleando secuencias truncadas a 128 *tokens*, lotes de tamaño 16 (*batch size*), el optimizador AdamW con una tasa de aprendizaje de 2×10^{-5} y parada temprana fijada a un máximo de 10 *epochs*.

- **MarianMT (Helsinki-NLP)**. Modelo de traducción neuronal de extrema ligereza (78 millones de parámetros) originado de la iniciativa OPUS-MT del grupo Helsinki-NLP [73], del cual se ha implementado la versión *Helsinki-NLP/opus-mt-zh-en*. Utiliza la topología simétrica original del Transformer (6 capas de codificador, 6 de decodificador, sin *LayerNorm* inicial) y fue entrenado exclusivamente de forma supervisada sobre corpus bilingües del repositorio OPUS. Al carecer de la contaminación cruzada de otros idiomas, este modelo permite evaluar de forma aislada el rendimiento de una especialización puramente bilingüe frente a las representaciones semánticas compartidas de las redes multilingües masivas.
- **mBART-large-50**. Consisten en una escala masiva del diseño Seq2Seq propuesta por Meta AI [17] instanciada a través del modelo *facebook/mbart-large-50-many-to-many-mmt* (680 millones de parámetros y 12 capas en cada bloque). Se caracteriza un preentrenamiento auto-supervisado como auto-codificador de eliminación de ruido (*denoising*

autoencoder), donde reconstruye textos multilingües que han sido deliberadamente destruidos mediante enmascaramiento y barajado de secuencias. Esta capacidad de forzar al modelo a deducir el contexto faltante resulta de utilidad para procesar la literatura *wuxia*, cuyas *webnovels* originales en chino suelen presentar estructuras gramaticales elípticas, onomatopeyas y un registro coloquial a menudo fragmentado.

- **mT5-small**. Variante de la arquitectura *Text-to-Text* de Google [74], implementada bajo el modelo *google/mt5-small* (300 millones de parámetros). Fue preentrenado de manera no supervisada sobre 101 idiomas mediante corrupción de tramos sobre mC4, abarcando casi 1 billón de tokens. Una particularidad de esta red es su gigantesco espacio de *embeddings*, soportado por un tokenizador SentencePiece de 250.000 palabras con respaldo a nivel de byte para no rechazar caracteres inexplorados, lo que puede resultar de utilidad en el contexto de este trabajo.
- **M2M-100** (418M). Fue el primer sistema Transformer diseñado por Meta para traducir directamente entre 100 lenguas de forma ortogonal [18] (utilizando la configuración *facebook/m2m100_418M*), eliminando el sesgo histórico de utilizar el inglés como idioma pivote. Su preentrenamiento supervisado se equilibró dinámicamente mediante muestreo estocástico de temperatura para evitar que los idiomas dominantes en la red colapsaran los pesos de la matriz. Al mapear tanto el chino como el inglés en un espacio semántico compartido y equidistante, el modelo busca reducir la pérdida de información cultural que se produce al trasladar conceptos filosóficos taoístas o budistas que carecen de una equivalencia literal en Occidente.

6.6 Adaptación al dominio

Tal y como se ha adelantado, la aplicación de *fine-tuning* resulta necesaria debido a que estos modelos, a pesar de su masivo preentrenamiento, son altamente susceptibles a sufrir de la desviación de dominio (también conocido como *domain shift*). Arquitecturas como mBART o mT5 han interiorizado distribuciones probabilísticas basadas fundamentalmente en textos contemporáneos, noticias o actas parlamentarias. En consecuencia, al intentar traducir terminología más específicas o escenarios más complejos, sus proyecciones en el espacio latente fracasan. Este desajuste provoca alucinaciones semánticas, omisiones y la pérdida de la estética original del autor.

Para corregir este problema, se aplica el aprendizaje por transferencia reentrenando los modelos de forma supervisada con el corpus bilingüe preparado en el capítulo cuarto 4. Durante este proceso, los parámetros internos de las redes se actualizan para asimilar el nuevo

contexto. De este modo, el sistema pierde su tendencia a generar traducciones genéricas y aprende a replicar tanto la terminología específica como el estilo narrativo propios de la literatura fantástica china.

Una vez completada esta adaptación, más adelante se evaluará el rendimiento de las cinco arquitecturas para medir la calidad de sus traducciones y poder compararlas con los distintos LLMs con los que se trabajaran en el siguiente capítulo.

6.7 Entrenamiento

Antes de evaluar la calidad de las traducciones, conviene analizar cómo se comportó cada modelo durante esta fase de entrenamiento.

En esta tabla se recogen los datos extraídos al finalizar el entrenamiento. Todos los procesos incluyeron un sistema de parada temprana, configurado para detener la ejecución automáticamente si la pérdida de validación dejaba de mejorar, evitando así que el modelo memorizara los datos de forma innecesaria.

Grandes modelos de lenguaje

COMO se ha expuesto en capítulos anteriores, la traducción automática ha evolucionado en su intento por procesar la complejidad semántica y cultural de las lenguas humanas. La disciplina dejó atrás los rígidos sistemas basados en reglas y los modelos estadísticos para dar paso a el aprendizaje profundo mediante la traducción automática neuronal. El enfoque clásico de esta etapa, fundamentado en arquitecturas *Sequence-to-Sequence*, supuso una revolución al dejar de traducir palabras aisladas para proyectar oraciones completas en un espacio semántico continuo. Sin embargo, estas primeras redes sufrían un grave problema de diseño: al depender de redes recurrentes, comprimían toda la información de la frase en un único vector de contexto de tamaño fijo. Este cuello de botella limitaba severamente su capacidad para recordar información y traducir textos extensos sin perder el hilo gramatical.

El verdadero hito tecnológico llegó con la introducción de los mecanismos de atención y, muy especialmente, con la arquitectura Transformer propuesta por Vaswani et al. [10]. Al eliminar la recurrencia matemática, esta red permitió procesar todas las palabras en paralelo y relacionar términos muy distantes dentro de un mismo texto sin perder el contexto.

A partir de aquí, se puede decir que el Procesamiento del Lenguaje Natural se bifurcó en dos grandes líneas de investigación. Por un lado, se consolidaron los modelos basados en la topología completa de codificador-decodificador (como los ya mencionados mBART o mT5). Estas redes han dominado históricamente los sistemas de traducción puros, ya que el codificador "lee" toda la secuencia de origen y el decodificador genera la secuencia de destino. Por otro lado, la industria apostó por escalar de forma masiva una topología más simple, basada exclusivamente en la parte generativa de la red (*decoder-only*). Es precisamente esta segunda vía de desarrollo la que ha propiciado el estallido tecnológico de los actuales Grandes Modelos de Lenguaje (LLMs).

7.1 El paradigma *Decoder-only*

A diferencia de los modelos codificador-decodificador que optimizan representaciones bi-direccionales, las arquitecturas *decoder-only* operan bajo un paradigma de modelado de lenguaje causal o autorregresivo. El objetivo algorítmico de estas redes es predecir la distribución de probabilidad del siguiente *token* en una secuencia, condicionado exclusivamente a los *tokens* que le preceden. Matemáticamente, el modelo busca maximizar la probabilidad conjunta de una secuencia de texto $X = (x_1, x_2, \dots, x_n)$, factorizada mediante la regla de la cadena:

$$P(X) = \prod_{i=1}^n P(x_i | x_1, x_2, \dots, x_{i-1}; \Theta)$$

donde Θ representa el conjunto de parámetros entrenables de la red. Aunque este objetivo se diseñó inicialmente para la generación de texto monolingüe, el estudio de las Leyes de Escalado [75] reveló una dinámica crucial. Kaplan et al. demostraron que la pérdida de entropía cruzada disminuye siguiendo una ley de potencias predecible a medida que se incrementan el recuento de parámetros, el tamaño del conjunto de datos y el cómputo utilizado.

Al escalar estas arquitecturas sobre corpus que abarcan billones de *tokens* en múltiples idiomas, la red neuronal se ve forzada a interiorizar estructuras gramaticales profundas, conocimiento del mundo y relaciones lingüísticas complejas para poder minimizar su error de predicción. Este proceso da lugar a la aparición de habilidades emergentes [76], definidas por Wei et al. como capacidades ausentes en modelos pequeños que afloran al alcanzar cierta escala computacional, estas habilidades incluyen la capacidad de traducir entre idiomas con alta naturalidad sin requerir supervisión explícita ni datos estrictamente alineados. Este fenómeno ha desplazado el paradigma de la traducción: el esfuerzo ya no recae tanto en la recopilación de corpus paralelos masivos, sino en el modelado de lenguaje a escala.

Estudios como los de Jiao et al. [1] y Hendy et al. [2] demostraron que los LLMs instruidos igualan o superan a los motores neuronales clásicos, beneficiándose de una comprensión semántica mucho más profunda. Posteriormente, investigaciones centradas explícitamente en la traducción literaria y la preservación del tono, como las desarrolladas por Karpinska et al. [24], han evidenciado que la ventaja de los modelos generativos no radica únicamente en la precisión léxica, sino en su capacidad para resolver ambigüedades pragmáticas y adaptar referencias culturales complejas sin necesidad de diccionarios externos.

Esta capacidad se amplifica cuando se evalúa la traducción a nivel de documento completo. Las arquitecturas NMT convencionales procesan el texto oración por oración, lo que

puede provocar una amnesia contextual que destruye la coherencia de los pronombres, el tono y las jerarquías en la traducción literaria. Los LLMs, por el contrario, han ampliado sus ventanas de contexto hasta superar los millones de *tokens* [77] y han integrado capacidades de razonamiento avanzado [78, 79]. Al disponer de un contexto mucho más amplio y poder analizar la información antes de generar la respuesta, el modelo mitiga el cuello de botella narrativo, favoreciendo que la traducción de novelas mantenga una consistencia estilística y referencial a lo largo de toda la obra.

7.2 Selección de modelos

La rápida evolución de los grandes modelos de lenguaje dificulta la evaluación de todas las arquitecturas disponibles. Por este motivo, este trabajo descarta el entrenamiento desde cero y opta por emplear modelos fundacionales de pesos abiertos (*open-weights*). La selección de los candidatos se ha basado en cuatro criterios técnicos específicos: soporte multilingüe para el par chino-inglés, ventanas de contexto amplias adecuadas para el procesamiento literario, alta capacidad para seguir instrucciones (*instruction tuning*), y un tamaño comprendido entre 20 y 100 miles de millones de parámetros (27B - 70B). Este rango dimensional ofrece un equilibrio entre las capacidades de razonamiento de la red y la viabilidad computacional de su ejecución o ajuste mediante técnicas de cuantización. Partiendo de estas premisas, se han seleccionado cuatro modelos publicados entre 2024 y 2025, representativos de distintas familias arquitectónicas.

7.2.1 Llama 3.3 70B Instruct (Meta)

Publicado por Meta a finales de 2024, Llama 3.3 70B Instruct es un modelo autorregresivo denso optimizado para el diálogo multilingüe y el seguimiento de instrucciones complejas [80]. Con 70.000 millones de parámetros y un preentrenamiento basado en un corpus que supera los 15 billones de *tokens*, este modelo alcanza un rendimiento equiparable a modelos contemporáneos en diversas métricas de evaluación.

A nivel arquitectónico, destaca por la implementación de la Atención de Consultas Agrupadas (*Grouped-Query Attention*, GQA). Mientras que la atención multicabecal estándar exige almacenar en memoria un vector de Clave y Valor (KV) por cada cabezal de Consulta, provocando una rápida saturación de la VRAM al procesar inferencias con ventanas largas, la GQA agrupa múltiples cabezales para que compartan un único par KV. Esta optimización permite al modelo gestionar ventanas de contexto de hasta 128.000 *tokens* sin una degradación significativa de la latencia.

7.2.2 GLM-4 32B (Zhipu AI)

El modelo GLM-4 32B, desarrollado conjuntamente por Zhipu AI y la Universidad de Tsinghua, constituye una evolución destacada de la arquitectura *General Language Model* [81]. Con 32.000 millones de parámetros, este modelo ofrece un rendimiento competitivo frente a otras alternativas, destacando especialmente por su fuerte optimización nativa para el idioma chino. Su preentrenamiento incorpora un volumen sustancial de datos sintéticos enfocados en tareas de razonamiento, lo que refuerza su capacidad para el análisis lógico y deductivo.

A nivel estructural, la familia GLM modifica varios componentes del bloque Transformer tradicional. Entre sus innovaciones destaca la implementación de la Codificación Posicional Rotatoria Bidimensional (2D RoPE) para procesar la información espacial y contextual con mayor precisión, así como la sustitución de la normalización estándar por RMSNorm combinada con la función de activación SwiGLU. Un aspecto técnico relevante para su eficiencia es la eliminación de los términos de sesgo (*bias*) en la mayoría de las capas lineales, conservándolos de forma exclusiva en las proyecciones de las matrices de Consulta, Clave y Valor (QKV) dentro del mecanismo de atención. Esta especialización hacia el mandarín reduce el riesgo de pérdida semántica al procesar textos con una alta densidad.

En el contexto de este trabajo, se plantea que esta base nativa facilitará la traducción de conceptos propios del género *wuxia*, un área donde los modelos entrenados predominantemente con corpus occidentales suelen presentar deficiencias.

7.2.3 Gemma 3 27B IT (Google DeepMind)

Publicado a principios de 2025, Gemma 3 27B IT es un modelo de pesos abiertos de Google DeepMind, construido sobre la misma infraestructura tecnológica que la serie Gemini [82].

Para gestionar eficazmente su ventana de contexto de 128.000 *tokens* y evitar el colapso de la memoria de la caché KV, Google introdujo modificaciones estructurales en el diseño topológico. El modelo emplea una alta proporción de capas de atención local intercaladas con capas globales. Al mantener la atención local de corto alcance e incrementar la frecuencia base del mecanismo RoPE (de 10.000 a 1.000.000) de manera exclusiva en las capas de auto-atención global, la arquitectura logra recuperar contexto distante sin incurrir en el elevado coste computacional de procesar la atención completa sobre cada bloque. Asimismo, el modelo sustituye el mecanismo de *soft-capping* empleado en iteraciones previas por la técnica de normalización QK para asegurar la estabilidad numérica a gran escala.

7.2.4 Qwen 3 30B Instruct (Alibaba Cloud)

para completar el marco experimental de *fine-tuning*, se incluye Qwen 3 30B Instruct, publicado por Alibaba Cloud en 2025 [83]. Esta familia de modelos destaca por su amplia cobertura multilingüe, ofreciendo soporte nativo para 119 idiomas y dialectos. En concreto, la versión seleccionada (Qwen3-30B-A3B-Instruct-2507) se caracteriza por unificar distintos paradigmas de inferencia dentro de una misma arquitectura.

La principal innovación de Qwen 3 radica en la integración dinámica de un modo de razonamiento latente (*thinking mode*) y un modo de respuesta directa (*non-thinking mode*). En función de la complejidad de la instrucción, la red puede asignar de forma dinámica una mayor capacidad de cómputo para generar cadenas de pensamiento deductivo antes de emitir la salida textual. Se hipotetiza que esta capacidad de análisis reflexivo resultará de utilidad para resolver las ambigüedades de la literatura *wuxia* y *xianxia*. Teóricamente, el modelo puede emplear este cálculo previo para analizar la etimología de una técnica marcial o un concepto filosófico en su espacio latente antes de determinar su equivalencia más adecuada al inglés. Asimismo, la arquitectura incorpora un método de extrapolación de longitud libre de entrenamiento, apoyado en mecanismos de atención dispersa. Estas optimizaciones le permiten gestionar ventanas de contexto de hasta un millón de *tokens*, facilitando el procesamiento íntegro de documentos extensos.

7.3 Métodos de Inferencia e Ingeniería de Prompts

El rendimiento de un LLM no depende exclusivamente del tamaño de su arquitectura, sino de cómo se condiciona su proceso de inferencia. La ingeniería de prompts *prompt engineering* se ha consolidado como la metodología estándar para guiar el comportamiento generativo de estas redes, alineando su salida con los requisitos estilísticos y terminológicos de la tarea. Para la literatura *wuxia*, donde el equilibrio entre la literalidad y la adaptación cultural define la experiencia del lector occidental, el diseño de estas instrucciones de entrada resulta igual de importante que la propia arquitectura subyacente [24, 84].

7.3.1 Aprendizaje en Contexto (In-Context Learning)

A diferencia de la Traducción Automática Neuronal tradicional, que aplica de forma estática los pesos ajustados durante su fase de entrenamiento, los LLMs pueden aprovechar *In-Context Learning* (ICL) [85]. El ICL permite al modelo inferir la naturaleza de la tarea y adaptar su respuesta basándose en las directrices y ejemplos proporcionados en su ventana de contexto inmediato, sin necesidad de retropropagar ni actualizar sus pesos.

En el ámbito de la traducción con LLMs, el ICL se implementa habitualmente mediante dos estrategias:

- **Zero-Shot Translation:** El modelo recibe únicamente la instrucción del sistema y el texto a traducir, sin demostraciones previas. Su eficacia recae en la calidad de su preentrenamiento y en la claridad semántica del *prompt* para activar el comportamiento de traducción adecuado.
- **Few-Shot Translation:** Consiste en incluir un conjunto reducido de ejemplos (pares de texto origen y su traducción de referencia) dentro de la instrucción antes de enviar la solicitud final [86]. En la traducción de novelas de artes marciales, esta técnica actúa como un glosario dinámico. Al exponer al modelo a ejemplos concretos sobre cómo adaptar rangos jerárquicos (p. ej., "Gran Anciano" o "Patriarca") o niveles de cultivo (p. ej., de "Condensación de Qi" a "Establecimiento de la Fundación"), el sistema ancla su generación a ese patrón léxico. Esto ayuda a mitigar las inconsistencias terminológicas a lo largo del documento.

7.3.2 Diseño de plantillas de instrucción

Para evaluar la capacidad de adaptación de los modelos seleccionados sin recurrir a la modificación de sus parámetros internos mediante *fine-tuning*, se han definido seis plantillas de instrucciones (*Prompt Templates*). Estos prompts actúan como implementaciones prácticas de distintos métodos de traducción, abarcando un espectro que va desde la equivalencia formal (preservación de la sintaxis original) hasta la equivalencia dinámica (adaptación del mensaje priorizando su impacto en el lector occidental).

A continuación se detalla la configuración para cada escenario de evaluación:

- **0. Baseline neutral:** Diseñado para establecer un punto de control sin sesgo estilístico. Sirve para medir el comportamiento predeterminado del modelo frente al texto literario de origen.

Mensaje del Sistema: "You are a Chinese-to-English translator. Output only the translated text inside [[[and]]]. Translate the following Chinese text into English:"

- **1. Adaptación fantástica:** Orientado a la equivalencia dinámica. Instruye al modelo a sacrificar la exactitud literal en favor de la fluidez narrativa, mitigando expresiones abstractas en beneficio del ritmo de la acción.

Mensaje del Sistema: "Your role is an assistant transforming Chinese wuxia text into gripping English fantasy prose. Adapt idioms and cultural references to be easily understood by Western readers while keeping the specific wuxia flavor. Prioritize narrative pacing and emotional impact over word-for-word accuracy."

- **2. Esteticismo literario:** Fuerza al modelo a actuar como un agente cultural. Requiere trasladar la densidad poética de las descripciones ambientales y el misticismo del texto original al inglés sin perder precisión semántica.

Mensaje del Sistema: "You are an expert literary translator of Chinese wuxia fiction. Retain the poetic flow, cultural symbolism, and epic atmosphere characteristic of wuxia narratives. The goal is to produce English reflecting the depth of Chinese idioms."

- **3. Emulación NMT:** Restringe la naturaleza conversacional del LLM. Busca obligar al sistema a emular un decodificador estadístico tradicional (*Seq2Seq*), forzando la máxima fidelidad estructural y suprimiendo reformulaciones.

Mensaje del Sistema: "You are functioning as a seq2seq neural translation model. You must produce a one-to-one translation of the source text without commentary, explanation, or rephrasing."

- **4. Académico bilingüe:** Desplaza la generación hacia un registro académico y formal. Resulta adecuado para evaluar pasajes de exposición teórica sobre sistemas filosóficos, reglas daoístas o tratados marciales.

Mensaje del Sistema: "You are a bilingual scholar translating Chinese martial arts literature into English. Your translation must be accurate, faithful, and formal."

Además, una tendencia metodológica habitual al utilizar LLMs es su tendencia a decodificar los nombres propios por su significado semántico. Por ejemplo, el nombre del personaje "Suan Bu Jin" (cuya traducción literal es "Endless/Countless calculations") provocó que los modelos devolvieran variaciones erráticas a lo largo de las pruebas, generando salidas como "Unfathomable by calculation", "Incomprehensible calculations" o "You cannot calculate every variable". Para evitar que estas discrepancias destruyeran la cohesión narrativa, se inyectó una restricción transversal en todos los *prompts*: "Convert all Chinese personal names, place names, and martial arts terms into pinyin romanization". Finalmente, se instruyó a los modelos para encapsular su traducción en la respuesta entre los delimitadores [[[y]]], facilitando así la extracción de la traducción en caso de que el LLM decida generar explicaciones u otros elementos.

7.4 *Fine-tuning*

A pesar de la eficacia de la Ingeniería de *Prompts* y la capacidad de adaptación del Aprendizaje en Contexto (*Few-Shot*), depender exclusivamente de la inferencia base presenta limitaciones operativas. El uso de instrucciones y demostraciones excesivamente largas satura la ventana de contexto, lo que incrementa exponencialmente el coste computacional asociado al mecanismo de atención. Además, la terminología específica del *jianghu* y los sistemas de

progresión del cultivo inmortal constituyen un dominio de conocimiento muy acotado. Este léxico difiere de manera significativa de las distribuciones estadísticas generales que los modelos asimilan durante su fase de preentrenamiento. Por consiguiente, para desarrollar un sistema verdaderamente especializado en la traducción de literatura *wuxia*, resulta necesario codificar este conocimiento directamente en los pesos matriciales de la red neuronal, similar a lo realizado en el capítulo anterior 7.

7.4.1 Eficiencia Paramétrica: PEFT y LoRA

El *afine-tuning* tradicional, que implica el cálculo de gradientes y la actualización de todos los parámetros del modelo de forma simultánea y que se aplicó en los modelos NMT, resultó metodológicamente inviable para arquitecturas de entre 27.000 y 70.000 millones de parámetros en la infraestructura utilizada en el entrenamiento. La memoria VRAM requerida para almacenar los parámetros del modelo, los estados de los optimizadores y los tensores de activación superaría con creces los cientos de gigabytes.

La solución encontrada a esta limitación algorítmica reside en el Ajuste Fino Eficiente en Parámetros (*Parameter-Efficient Fine-Tuning*, PEFT). Esta metodología permite la adaptación al dominio de la traducción entrenando únicamente una fracción residual de parámetros adicionales, mientras que el modelo base permanece intacto. Dentro de este marco, el protocolo seleccionado para la arquitectura del proyecto ha sido LoRA (*Low-Rank Adaptation*)

Formulado originalmente por Hu et al. [87], LoRA se fundamenta en la hipótesis de que los cambios dinámicos necesarios para adaptar un modelo masivo a una tarea específica residen en una dimensión intrínseca de bajo rango. Bajo este principio, la matriz de pesos preentrenada original, $W_0 \in \mathbb{R}^{d \times k}$, se congela por completo (deshabilitando el cálculo de sus gradientes). En su lugar, se inyecta un módulo de derivación paralelo compuesto por dos matrices densas de rango bajo, $A \in \mathbb{R}^{r \times k}$ y $B \in \mathbb{R}^{d \times r}$, donde el rango r es un hiperparámetro muy pequeño ($r \ll \min(d, k)$).

El *forward pass* para un tensor de entrada x se reformula como:

$$h = W_0x + \Delta Wx = W_0x + BAx$$

Durante la fase de retropropagación, el optimizador calcula exclusivamente los gradientes para las pequeñas matrices A y B . Esta descomposición matemática reduce drásticamente la cantidad de parámetros entrenables (llegando a factores de reducción de 10.000 en arquitecturas masivas según Hu et al.) y disminuye los requisitos de memoria VRAM en fracciones

significativas. Estas optimizaciones permiten que modelos de gran envergadura converjan eficientemente hacia el estilo literario *wuxia*, mitigando en gran medida el fenómeno de olvido catastrófico asociado al ajuste tradicional.

7.4.2 Cuantización de redes: El protocolo QLoRA

Incluso con la reducción de parámetros que aporta LoRA, la carga en memoria de los pesos base congelados (W_0) de modelos como Llama 3.3 o Qwen 3 superaría la capacidad de la VRAM disponible si se instanciaran en precisión de coma flotante estándar de 16 bits (BF16 o FP16). Para solventar esta restricción física del hardware, la metodología implementada en el entrenamiento integró el protocolo QLoRA (*Quantized LoRA*) mediante la configuración *BitsAndBytesConfig* de la librería *Transformers*.

La cuantización es una transformación que proyecta los valores continuos de alta precisión de los pesos neuronales hacia espacios discretos de representación reducida. En este estudio, los modelos fundacionales se cargaron bajo una topología de cuantización de 4 bits utilizando el formato de datos NF4 (*NormalFloat4*). Este tipo de datos está optimizado desde la teoría de la información para mapear tensores de redes neuronales que siguen distribuciones normales.

A pesar de que los pesos base se almacenan en una resolución de 4 bits, la preservación de la calidad en la traducción literaria exige una fidelidad numérica en las capas dinámicas. Por ello, los cálculos vectoriales y las activaciones intermedias durante la propagación hacia adelante de LoRA se ejecutaron descuantizando temporalmente los valores al espacio de representación BFloat16. Este flujo de trabajo permite una convergencia de entrenamiento eficiente sin degradar la complejidad lingüística ni la capacidad generativa del modelo.

7.4.3 Configuración de hiperparámetros experimentales

Para garantizar el rigor del experimento, las cuatro arquitecturas (Llama 3.3, GLM-4, Gemma 3 y Qwen 3) se ajustaron utilizando la clase *Trainer* y *LoraConfig* de la biblioteca *Transformers* bajo una topología de hiperparámetros estandarizada:

- Restricciones dimensionales (LoRA): Se estableció un rango intrínseco $r = 16$ y un parámetro de escalado $\alpha = 32$. Esta relación ($\frac{\alpha}{r} = 2$) aplica un factor de amplificación sobre las matrices densas para acelerar la asimilación estilística temprana. Se aplicó un *dropout* del 5% para mitigar el sobreajuste y favorecer la generalización gramatical.
- Mapeo de módulos objetivo: Normalmente, la investigación sobre PEFT sugería acoplar LoRA únicamente a las matrices de Consulta y Valor (Q y V). No obstante, para

dominar el mapeo cruzado del chino al inglés requerido este trabajo, la intervención se expandió sistemáticamente hacia la totalidad de los tensores de autoatención y los módulos perceptivos multicapa de proyección profunda. Se declararon como objetivo siete proyecciones: [q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj]. Esta intervención fuerza al modelo a reconectar tanto su capacidad para asignar atención a entidades distantes como su lógica discursiva interna oculta.

- Optimizador y yasa de aprendizaje: Se empleó el optimizador asíncrono *AdamW* (en su versión paginada de 32 bits para modelos cuantizados) con una tasa de aprendizaje de 2×10^{-4} . El entrenamiento se limitó a una única época para prevenir el sobreajuste sobre el corpus.
- Lotes y acumulación de gradientes: Debido a las limitaciones de VRAM, el tamaño de lote físico se limitó a 4 secuencias simultáneas (1 para la arquitectura de GLM-4, debido a la alta huella de memoria VRAM de sus tensores de activación). Para estabilizar la trayectoria del gradiente, se configuró una acumulación de 16 iteraciones (64 para GLM-4), logrando un lote virtual efectivo de 64 secuencias en los 4 modelos.

A diferencia de la metodología de inferencia, la preparación de los tensores para el *fine-tuning* prescindió de las plantillas de *prompts*. Las secuencias se estandarizaron truncando a 512 posiciones bajo una instrucción unificada: el sistema partió del rol latente *"You are an expert translator specializing in Chinese Wuxia fiction to English."*, instruyendo al modelo con *"Translate the following Chinese text to English: \n {texto_chino}"* y forzando la reconstrucción matemática exacta del texto de referencia provisto en el corpus humano.

7.4.4 estadísticas del entrenamiento?

Conclusións

DERRADEIRO capítulo da memoria, onde se presentará a situación final do traballo, as leccións aprendidas, a relación coas competencias da titulación en xeral e a mención en particular, posibles liñas futuras,...

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique

neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Apéndices

Material adicional

EXEMPLO de capítulo con formato de apéndice, onde se pode incluír material adicional que non teña cabida no corpo principal do documento, suxeito á limitación de 80 páxinas establecida no regulamento de TFGs.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique

neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

Bibliografía

- [1] W. Jiao, W. Wang, J. tse Huang, X. Wang, S. Shi, and Z. Tu, “Is chatgpt a good translator? yes with gpt-4 as the engine,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2301.08745>
- [2] A. Hendy, M. Abdelrehim, A. Sharaf, V. Raunak, M. Gabr, H. Matsushita, Y. J. Kim, M. Afify, and H. H. Awadalla, “How good are gpt models at machine translation? a comprehensive evaluation,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2302.09210>
- [3] W. Zhu, H. Liu, Q. Dong, J. Xu, S. Huang, L. Kong, J. Chen, and L. Li, “Multilingual machine translation with large language models: Empirical results and analysis,” 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2304.04675>
- [4] C. Gómez-Rodríguez and P. Williams, “A confederacy of models: a comprehensive evaluation of LLMs on creative writing,” in *Findings of the Association for Computational Linguistics: EMNLP 2023*, H. Bouamor, J. Pino, and K. Bali, Eds. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 14 504–14 528. [En línea]. Disponible en: <https://aclanthology.org/2023.findings-emnlp.966/>
- [5] T. Chakrabarty, P. Laban, D. Agarwal, S. Muresan, and C.-S. Wu, “Art or artifice? large language models and the false promise of creativity,” 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2309.14556>
- [6] G. Marco, L. Rello, and J. Gonzalo, “Small language models can outperform humans in short creative writing: A study comparing slms with humans and llms,” 2025. [En línea]. Disponible en: <https://arxiv.org/abs/2409.11547>
- [7] W. Weaver, “Translation,” New York, July 1949, memorandum, Rockefeller Foundation. [En línea]. Disponible en: <https://www.mt-archive.net/50/Weaver-1949.pdf>

- [8] P. F. Brown, J. Cocke, S. A. Della Pietra, V. J. Della Pietra, F. Jelinek, J. D. Lafferty, R. L. Mercer, and P. S. Roossin, “A statistical approach to machine translation,” *Computational Linguistics*, vol. 16, no. 2, pp. 79–85, 1990. [En línea]. Disponible en: <https://aclanthology.org/J90-2002/>
- [9] P. F. Brown, S. A. Della Pietra, V. J. Della Pietra, and R. L. Mercer, “The mathematics of statistical machine translation: Parameter estimation,” *Computational linguistics*, vol. 19, no. 2, pp. 263–311, 1993.
- [10] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/1706.03762>
- [11] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “Bert: Pre-training of deep bidirectional transformers for language understanding,” 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1810.04805>
- [12] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, “Roberta: A robustly optimized bert pretraining approach,” 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1907.11692>
- [13] J. Zhu, Y. Xia, L. Wu, D. He, T. Qin, W. Zhou, H. Li, and T.-Y. Liu, “Incorporating bert into neural machine translation,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2002.06823>
- [14] S. Clinchant, K. W. Jung, and V. Nikoulina, “On the use of BERT for neural machine translation,” in *Proceedings of the 3rd Workshop on Neural Generation and Translation*, A. Birch, A. Finch, H. Hayashi, I. Konstas, T. Luong, G. Neubig, Y. Oda, and K. Sudoh, Eds. Hong Kong: Association for Computational Linguistics, Nov. 2019, pp. 108–117. [En línea]. Disponible en: <https://aclanthology.org/D19-5611/>
- [15] M. Lewis, Y. Liu, N. Goyal, M. Ghazvininejad, A. Mohamed, O. Levy, V. Stoyanov, and L. Zettlemoyer, “BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, D. Jurafsky, J. Chai, N. Schluter, and J. Tetreault, Eds. Online: Association for Computational Linguistics, Jul. 2020, pp. 7871–7880. [En línea]. Disponible en: <https://aclanthology.org/2020.acl-main.703/>
- [16] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/1910.10683>

- [17] Y. Liu, J. Gu, N. Goyal, X. Li, S. Edunov, M. Ghazvininejad, M. Lewis, and L. Zettlemoyer, “Multilingual denoising pre-training for neural machine translation,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2001.08210>
- [18] A. Fan, S. Bhosale, H. Schwenk, Z. Ma, A. El-Kishky, S. Goyal, M. Baines, O. Celebi, G. Wenzek, V. Chaudhary, N. Goyal, T. Birch, V. Liptchinsky, S. Edunov, M. Auli, and A. Joulin, “Beyond english-centric multilingual machine translation,” *Journal of Machine Learning Research*, vol. 22, no. 107, pp. 1–48, 2021. [En línea]. Disponible en: <http://jmlr.org/papers/v22/20-1307.html>
- [19] N. Team, M. R. Costa-jussà, J. Cross, O. Çelebi, M. Elbayad, K. Heafield, K. Heffernan, E. Kalbassi, J. Lam, D. Licht, J. Maillard, A. Sun, S. Wang, G. Wenzek, A. Youngblood, B. Akula, L. Barrault, G. M. Gonzalez, P. Hansanti, J. Hoffman, S. Jarrett, K. R. Sadagopan, D. Rowe, S. Spruit, C. Tran, P. Andrews, N. F. Ayan, S. Bhosale, S. Edunov, A. Fan, C. Gao, V. Goswami, F. Guzmán, P. Koehn, A. Mourachko, C. Ropers, S. Saleem, H. Schwenk, and J. Wang, “No language left behind: Scaling human-centered machine translation,” 2022. [En línea]. Disponible en: <https://arxiv.org/abs/2207.04672>
- [20] M. Müller, A. Rios, and R. Sennrich, “Domain robustness in neural machine translation,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/1911.03109>
- [21] C. Chu and R. Wang, “A survey of domain adaptation for neural machine translation,” 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1806.00258>
- [22] P. Koehn, *Neural Machine Translation*. Cambridge University Press, 2020, ch. 13.
- [23] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, “Language models are few-shot learners,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2005.14165>
- [24] M. Karpinska and M. Iyyer, “Large language models effectively leverage document-level context for literary translation, but critical errors persist,” in *Proceedings of the Eighth Conference on Machine Translation*, P. Koehn, B. Haddow, T. Kocmi, and C. Monz, Eds. Singapore: Association for Computational Linguistics, Dec. 2023, pp. 419–451. [En línea]. Disponible en: <https://aclanthology.org/2023.wmt-1.41/>
- [25] Y. Moslem, R. Haque, J. D. Kelleher, and A. Way, “Adaptive machine translation with large language models,” in *Proceedings of the 24th Annual Conference of the European*

- Association for Machine Translation*, M. Nurminen, J. Brenner, M. Koponen, S. Latomaa, M. Mikhailov, F. Schierl, T. Ranasinghe, E. Vanmassenhove, S. A. Vidal, N. Aranberri, M. Nunziatini, C. P. Escartín, M. Forcada, M. Popovic, C. Scarton, and H. Moniz, Eds. Tampere, Finland: European Association for Machine Translation, Jun. 2023, pp. 227–237. [En línea]. Disponible en: <https://aclanthology.org/2023.eamt-1.22/>
- [26] M. Ghazvininejad, H. Gonen, and L. Zettlemoyer, “Dictionary-based phrase-level prompting of large language models for machine translation,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2302.07856>
- [27] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, “Survey of hallucination in natural language generation,” *ACM Computing Surveys*, vol. 55, no. 12, p. 1–38, Mar. 2023. [En línea]. Disponible en: <http://dx.doi.org/10.1145/3571730>
- [28] P. Koehn and R. Knowles, “Six challenges for neural machine translation,” 2017. [En línea]. Disponible en: <https://arxiv.org/abs/1706.03872>
- [29] K. Toutanova, A. Rumshisky, L. Zettlemoyer, D. Hakkani-Tur, I. Beltagy, S. Bethard, R. Cotterell, T. Chakraborty, and Y. Zhou, Eds., *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Online: Association for Computational Linguistics, Jun. 2021. [En línea]. Disponible en: <https://aclanthology.org/2021.naacl-main.0/>
- [30] N. M. Guerreiro, D. Alves, J. Waldendorf, B. Haddow, A. Birch, P. Colombo, and A. F. T. Martins, “Hallucinations in large multilingual translation models,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2303.16104>
- [31] E. Vanmassenhove, D. Shterionov, and M. Gwilliam, “Machine translationese: Effects of algorithmic bias on linguistic complexity in machine translation,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2102.00287>
- [32] Y. Bizzoni, T. S. Juzek, C. España-Bonet, K. Dutta Chowdhury, J. van Genabith, and E. Teich, “How human is machine translationese? comparing human and machine translations of text and speech,” in *Proceedings of the 17th International Conference on Spoken Language Translation*, M. Federico, A. Waibel, K. Knight, S. Nakamura, H. Ney, J. Niehues, S. Stüker, D. Wu, J. Mariani, and F. Yvon, Eds. Online: Association for Computational Linguistics, Jul. 2020, pp. 280–290. [En línea]. Disponible en: <https://aclanthology.org/2020.iwslt-1.34/>

- [33] I. Shumailov, Z. Shumaylov, Y. Zhao *et al.*, “Ai models collapse when trained on recursively generated data,” *Nature*, vol. 631, pp. 755–759, 2024. [En línea]. Disponible en: <https://doi.org/10.1038/s41586-024-07566-y>
- [34] G. Marco, J. Gonzalo, M. Mateo-Girona, and R. D. C. Santos, “Pron vs prompt: Can large language models already challenge a world-class fiction author at creative text writing?” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Y. Al-Onaizan, M. Bansal, and Y.-N. Chen, Eds. Miami, Florida, USA: Association for Computational Linguistics, Nov. 2024, pp. 19 654–19 670. [En línea]. Disponible en: <https://aclanthology.org/2024.emnlp-main.1096/>
- [35] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “Bleu: a method for automatic evaluation of machine translation,” in *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, P. Isabelle, E. Charniak, and D. Lin, Eds. Philadelphia, Pennsylvania, USA: Association for Computational Linguistics, Jul. 2002, pp. 311–318. [En línea]. Disponible en: <https://aclanthology.org/P02-1040/>
- [36] M. Snover, B. Dorr, R. Schwartz, L. Micciulla, and J. Makhoul, “A study of translation edit rate with targeted human annotation,” in *Proceedings of the 7th Conference of the Association for Machine Translation in the Americas: Technical Papers*. Cambridge, Massachusetts, USA: Association for Machine Translation in the Americas, Aug. 8-12 2006, pp. 223–231. [En línea]. Disponible en: <https://aclanthology.org/2006.amta-papers.25/>
- [37] M. Popović, “chrF: character n-gram F-score for automatic MT evaluation,” in *Proceedings of the Tenth Workshop on Statistical Machine Translation*, O. Bojar, R. Chatterjee, C. Federmann, B. Haddow, C. Hokamp, M. Huck, V. Logacheva, and P. Pecina, Eds. Lisbon, Portugal: Association for Computational Linguistics, Sep. 2015, pp. 392–395. [En línea]. Disponible en: <https://aclanthology.org/W15-3049/>
- [38] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, “Bertscore: Evaluating text generation with bert,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/1904.09675>
- [39] T. Sellam, D. Das, and A. Parikh, “BLEURT: Learning robust metrics for text generation,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, D. Jurafsky, J. Chai, N. Schluter, and J. Tetreault, Eds. Online: Association for Computational Linguistics, Jul. 2020, pp. 7881–7892. [En línea]. Disponible en: <https://aclanthology.org/2020.acl-main.704/>
- [40] R. Rei, C. Stewart, A. C. Farinha, and A. Lavie, “COMET: A neural framework for MT evaluation,” in *Proceedings of the 2020 Conference on Empirical Methods in*

- Natural Language Processing (EMNLP)*, B. Webber, T. Cohn, Y. He, and Y. Liu, Eds. Online: Association for Computational Linguistics, Nov. 2020, pp. 2685–2702. [En línea]. Disponible en: <https://aclanthology.org/2020.emnlp-main.213/>
- [41] A. Toral and A. Way, “What level of quality can neural machine translation attain on literary text?” 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1801.04962>
- [42] R. Zhang, W. Zhao, and S. Eger, “How good are LLMs for literary translation, really? literary translation evaluation with humans and LLMs,” in *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, L. Chiruzzo, A. Ritter, and L. Wang, Eds. Albuquerque, New Mexico: Association for Computational Linguistics, Apr. 2025, pp. 10 961–10 988. [En línea]. Disponible en: <https://aclanthology.org/2025.naacl-long.548/>
- [43] W. Kan and D. Li, “Are translated chinese wuxia fiction and western heroic literature similar? a stylometric analysis based on stylistic panoramas,” *Digital Scholarship in the Humanities*, vol. 37, 04 2022.
- [44] X. Ni, “Translating chinese identity crisis in and beyond jianghu: A case study of legends of the condor heroes,” *Humanities and Social Sciences Communications*, vol. 12, 08 2025.
- [45] G. Van Rossum and F. L. Drake, *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace, 2009.
- [46] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, “Pytorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems*, H. Wallach, H. Larochelle, A. Beygelzimer, F. d’Alché-Buc, E. Fox, and R. Garnett, Eds., vol. 32. Curran Associates, Inc., 2019. [En línea]. Disponible en: https://proceedings.neurips.cc/paper_files/paper/2019/file/bdbca288fee7f92f2bfa9f7012727740-Paper.pdf
- [47] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, J. Davison, S. Shleifer, P. von Platen, C. Ma, Y. Jernite, J. Plu, C. Xu, T. L. Scao, S. Gugger, M. Drame, Q. Lhoest, and A. M. Rush, “Huggingface’s transformers: State-of-the-art natural language processing,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/1910.03771>
- [48] Q. Lhoest, A. V. del Moral, Y. Jernite, A. Thakur, P. von Platen, S. Patil, J. Chaumond, M. Drame, J. Plu, L. Tunstall, J. Davison, M. Šaško, G. Chhablani, B. Malik, S. Brandeis,

- T. L. Scao, V. Sanh, C. Xu, N. Patry, A. McMillan-Major, P. Schmid, S. Gugger, C. Delangue, T. Matušíère, L. Debut, S. Bekman, P. Cistac, T. Goehringer, V. Mustar, F. Lagunas, A. M. Rush, and T. Wolf, “Datasets: A community library for natural language processing,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2109.02846>
- [49] S. Bird, E. Klein, and E. Loper, *Natural Language Processing with Python*, 01 2009.
- [50] M. Honnibal and I. Montani, “spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing,” *To appear*, 2018.
- [51] F. Feng, Y. Yang, D. Cer, N. Arivazhagan, and W. Wang, “Language-agnostic bert sentence embedding,” 2022. [En línea]. Disponible en: <https://arxiv.org/abs/2007.01852>
- [52] J. Yong, *The Legend of the Condor Heroes* (射鵰英雄傳). Hong Kong Commercial Daily, 1957, publicación seriada original (1957-1959). [En línea]. Disponible en: https://en.wikipedia.org/wiki/The_Legend_of_the_Condor_Heroes
- [53] —, *The Return of the Condor Heroes* (神鵰俠侶). Ming Pao, 1959, publicación seriada original (1959-1961). [En línea]. Disponible en: https://en.wikipedia.org/wiki/The_Return_of_the_Condor_Heroes
- [54] —, *The Heaven Sword and Dragon Saber* (倚天屠龍記). Ming Pao, 1961, publicación seriada original (1961-1963). [En línea]. Disponible en: https://en.wikipedia.org/wiki/The_Heaven_Sword_and_Dragon_Saber
- [55] Gu Zhen Ren, “Reverend insanity (盪真人),” Webnovel, 2012. [En línea]. Disponible en: https://www.webnovel.com/book/reverend-insanity_7996858406002505
- [56] Er Gen, “A will eternal (一念永恒),” Webnovel, 2016. [En línea]. Disponible en: <https://www.wuxiaworld.com/novel/a-will-eternal>
- [57] B. Thompson and P. Koehn, “Vecalign: Improved sentence alignment in linear time and space,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, K. Inui, J. Jiang, V. Ng, and X. Wan, Eds. Hong Kong, China: Association for Computational Linguistics, Nov. 2019, pp. 1342–1348. [En línea]. Disponible en: <https://aclanthology.org/D19-1136/>
- [58] L. Liu and M. Zhu, “Bertalign: Improved word embedding-based sentence alignment for chinese–english parallel corpora of literary texts,” *Digital Scholarship in the Humanities*, vol. 38, no. 2, pp. 621–634, 12 2022. [En línea]. Disponible en: <https://doi.org/10.1093/llc/fqac089>

- [59] M. Junczys-Dowmunt, “Dual conditional cross-entropy filtering of noisy parallel corpora,” 2019. [En línea]. Disponible en: <https://arxiv.org/abs/1809.00197>
- [60] R. Zhan, X. Liu, D. F. Wong, and L. S. Chao, “Variance-aware machine translation test sets,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2111.04079>
- [61] P. Baker, “Using corpora in discourse analysis,” 2006. [En línea]. Disponible en: <https://api.semanticscholar.org/CorpusID:60901766>
- [62] P. Koehn, *Statistical Machine Translation*, 01 2009.
- [63] C. E. Shannon, “A mathematical theory of communication,” *The Bell System Technical Journal*, vol. 27, no. 3, pp. 379–423, 1948. [En línea]. Disponible en: <https://onlinelibrary.wiley.com/doi/abs/10.1002/j.1538-7305.1948.tb01338.x>
- [64] P. Koehn, F. J. Och, and D. Marcu, “Statistical phrase-based translation,” in *Proceedings of the 2003 Human Language Technology Conference of the North American Chapter of the Association for Computational Linguistics*, 2003, pp. 127–133. [En línea]. Disponible en: <https://aclanthology.org/N03-1017/>
- [65] P. Koehn, H. Hoang, A. Birch, C. Callison-Burch, M. Federico, N. Bertoldi, B. Cowan, W. Shen, C. Moran, R. Zens, C. Dyer, O. Bojar, A. Constantin, and E. Herbst, “Moses: Open source toolkit for statistical machine translation,” in *Proceedings of the 45th Annual Meeting of the Association for Computational Linguistics Companion Volume Proceedings of the Demo and Poster Sessions*, S. Ananiadou, Ed. Prague, Czech Republic: Association for Computational Linguistics, Jun. 2007, pp. 177–180. [En línea]. Disponible en: <https://aclanthology.org/P07-2045/>
- [66] I. Sutskever, O. Vinyals, and Q. V. Le, “Sequence to sequence learning with neural networks,” 2014. [En línea]. Disponible en: <https://arxiv.org/abs/1409.3215>
- [67] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, “Learning phrase representations using rnn encoder-decoder for statistical machine translation,” 2014. [En línea]. Disponible en: <https://arxiv.org/abs/1406.1078>
- [68] M.-T. Luong, H. Pham, and C. D. Manning, “Effective approaches to attention-based neural machine translation,” 2015. [En línea]. Disponible en: <https://arxiv.org/abs/1508.04025>
- [69] K. Cho, B. van Merriënboer, D. Bahdanau, and Y. Bengio, “On the properties of neural machine translation: Encoder-decoder approaches,” 2014. [En línea]. Disponible en: <https://arxiv.org/abs/1409.1259>

- [70] D. Bahdanau, K. Cho, and Y. Bengio, “Neural machine translation by jointly learning to align and translate,” 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1409.0473>
- [71] R. Sennrich, B. Haddow, and A. Birch, “Neural machine translation of rare words with subword units,” 2016. [En línea]. Disponible en: <https://arxiv.org/abs/1508.07909>
- [72] T. Kudo and J. Richardson, “Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing,” 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1808.06226>
- [73] M. Junczys-Dowmunt, R. Grundkiewicz, T. Dwojak, H. Hoang, K. Heafield, T. Necker-mann, F. Seide, U. Germann, A. F. Aji, N. Bogoychev, A. F. T. Martins, and A. Birch, “Marian: Fast neural machine translation in c++,” 2018. [En línea]. Disponible en: <https://arxiv.org/abs/1804.00344>
- [74] L. Xue, N. Constant, A. Roberts, M. Kale, R. Al-Rfou, A. Siddhant, A. Barua, and C. Raffel, “mt5: A massively multilingual pre-trained text-to-text transformer,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2010.11934>
- [75] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, and D. Amodei, “Scaling laws for neural language models,” 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2001.08361>
- [76] J. Wei, Y. Tay, R. Bommasani, C. Raffel, B. Zoph, S. Borgeaud, D. Yogatama, M. Bosma, D. Zhou, D. Metzler, E. H. Chi, T. Hashimoto, O. Vinyals, P. Liang, J. Dean, and W. Fedus, “Emergent abilities of large language models,” 2022. [En línea]. Disponible en: <https://arxiv.org/abs/2206.07682>
- [77] G. Team, P. Georgiev, V. I. Lei, R. Burnell, L. Bai, A. Gulati, G. Tanzer, D. Vincent, Z. Pan, S. Wang, S. Mariooryad, Y. Ding, X. Geng, F. Alcober, R. Frostig, M. Omernick, L. Walker, C. Paduraru, C. Sorokin, A. Tacchetti, C. Gaffney, S. Daruki, O. Sercinoglu, Z. Gleicher, J. Love, P. Voigtlaender, R. Jain, G. Surita, K. Mohamed, R. Blevins, J. Ahn, T. Zhu, K. Kawintiranon, O. Firat, Y. Gu, Y. Zhang, M. Rahtz, M. Faruqui, N. Clay, J. Gilmer, J. Co-Reyes, I. Penchev, R. Zhu, N. Morioka, K. Hui, K. Haridasan, V. Campos, M. Mahdih, M. Guo, S. Hassan, K. Kilgour, A. Vezzer, H.-T. Cheng, R. de Liedekerke, S. Goyal, P. Barham, D. Strouse, S. Noury, J. Adler, M. Sundararajan, S. Vikram, D. Lepikhin, M. Paganini, X. Garcia, F. Yang, D. Valter, M. Trebacz, K. Vodrahalli, C. Asawaroengchai, R. Ring, N. Kalb, L. B. Soares, S. Brahma, D. Steiner, T. Yu, F. Mentzer, A. He, L. Gonzalez, B. Xu, R. L. Kaufman, L. E. Shafey, J. Oh, T. Hennigan, G. van den Driessche, S. Odoom, M. Lucic, B. Roelofs, S. Lall, A. Marathe, B. Chan, S. Ontanon, L. He, D. Teplyashin, J. Lai, P. Crone, B. Damoc, L. Ho, S. Riedel, K. Lenc,

- C.-K. Yeh, A. Chowdhery, Y. Xu, M. Kazemi, E. Amid, A. Petrushkina, K. Swersky, A. Khodaei, G. Chen, C. Larkin, M. Pinto, G. Yan, A. P. Badia, P. Patil, S. Hansen, D. Orr, S. M. R. Arnold, J. Grimstad, A. Dai, S. Douglas, R. Sinha, V. Yadav, X. Chen, E. Gribovskaya, J. Austin, J. Zhao, K. Patel, P. Komarek, S. Austin, S. Borgeaud, L. Friso, A. Goyal, B. Caine, K. Cao, D.-W. Chung, M. Lamm, G. Barth-Maron, T. Kagohara, K. Olszewska, M. Chen, K. Shivakumar, R. Agarwal, H. Godhia, R. Rajwar, J. Snaider, X. Dotiwalla, Y. Liu, A. Barua, V. Ungureanu, Y. Zhang, B.-O. Batsaikhan, M. Wirth, J. Qin, I. Danihelka, T. Doshi, M. Chadwick, J. Chen, S. Jain, Q. Le, A. Kar, M. Gurumurthy, C. Li, R. Sang, F. Liu, L. Lamprou, R. Munoz, N. Lintz, H. Mehta, H. Howard, M. Reynolds, L. Aroyo, Q. Wang, L. Blanco, A. Cassirer, J. Griffith, D. Das, S. Lee, J. Sygnowski, Z. Fisher, J. Besley, R. Powell, Z. Ahmed, D. Paulus, D. Reitter, Z. Borsos, R. Joshi, A. Pope, S. Hand, V. Selo, V. Jain, N. Sethi, M. Goel, T. Makino, R. May, Z. Yang, J. Schalkwyk, C. Butterfield, A. Hauth, A. Goldin, W. Hawkins, E. Senter, S. Brin, O. Woodman, M. Ritter, E. Noland, M. Giang, V. Bolina, L. Lee, T. Blyth, I. Mackinnon, M. Reid, O. Sarvana, D. Silver, A. Chen, L. Wang, L. Maggiore, O. Chang, N. Attaluri, G. Thornton, C.-C. Chiu, O. Bunyan, N. Levine, T. Chung, E. Eltyshev, X. Si, T. Lillicrap, D. Brady, V. Aggarwal, B. Wu, Y. Xu, R. McIlroy, K. Badola, P. Sandhu, E. Moreira, W. Stokowiec, R. Hemsley, D. Li, A. Tudor, P. Shyam, E. Rahimtoroghi, S. Haykal, P. Sprechmann, X. Zhou, D. Mincu, Y. Li, R. Addanki, K. Krishna, X. Wu, A. Frechette, M. Eyal, A. Dafoe, D. Lacey, J. Whang, T. Avrahami, Y. Zhang, E. Taropa, H. Lin, D. Toyama, E. Rutherford, M. Sano, H. Choe, A. Tomala, C. Safranek-Shrader, N. Kassner, M. Pajarskas, M. Harvey, S. Sechrist, M. Fortunato, C. Lyu, G. Elsayed, C. Kuang, J. Lottes, E. Chu, C. Jia, C.-W. Chen, P. Humphreys, K. Baumli, C. Tao, R. Samuel, C. N. dos Santos, A. Andreassen, N. Rakićević, D. Grewe, A. Kumar, S. Winkler, J. Caton, A. Brock, S. Dalmia, H. Sheahan, I. Barr, Y. Miao, P. Natsev, J. Devlin, F. Behbahani, F. Prost, Y. Sun, A. Myaskovsky, T. S. Pillai, D. Hurt, A. Lazaridou, X. Xiong, C. Zheng, F. Pardo, X. Li, D. Horgan, J. Stanton, M. Ambar, F. Xia, A. Lince, M. Wang, B. Mustafa, A. Webson, H. Lee, R. Anil, M. Wicke, T. Dozat, A. Sinha, E. Piqueras, E. Dabir, S. Upadhyay, A. Boral, L. A. Hendricks, C. Fry, J. Djolonga, Y. Su, J. Walker, J. Labanowski, R. Huang, V. Misra, J. Chen, R. Skerry-Ryan, A. Singh, S. Rijhwani, D. Yu, A. Castro-Ros, B. Changpinyo, R. Datta, S. Bagri, A. M. Hrafnkelsson, M. Maggioni, D. Zheng, Y. Sulsky, S. Hou, T. L. Paine, A. Yang, J. Riesa, D. Rogozinska, D. Marcus, D. E. Badawy, Q. Zhang, L. Wang, H. Miller, J. Greer, L. L. Sjos, A. Nova, H. Zen, R. Chaabouni, M. Rosca, J. Jiang, C. Chen, R. Liu, T. Sainath, M. Krikun, A. Polozov, J.-B. Lespiau, J. Newlan, Z. Cankara, S. Kwak, Y. Xu, P. Chen, A. Coenen, C. Meyer, K. Tsihla, A. Ma, J. Gottweis, J. Xing, C. Gu, J. Miao, C. Frank, Z. Cankara, S. Ganapathy, I. Dasgupta, S. Hughes-Fitt, H. Chen, D. Reid,

K. Rong, H. Fan, J. van Amersfoort, V. Zhuang, A. Cohen, S. S. Gu, A. Mohananey, A. Ilic, T. Tobin, J. Wieting, A. Bortsova, P. Thacker, E. Wang, E. Caveness, J. Chiu, E. Sezener, A. Kaskasoli, S. Baker, K. Millican, M. Elhawaty, K. Aisopos, C. Lebsack, N. Byrd, H. Dai, W. Jia, M. Wiethoff, E. Davoodi, A. Weston, L. Yagati, A. Ahuja, I. Gao, G. Pundak, S. Zhang, M. Azzam, K. C. Sim, S. Caelles, J. Keeling, A. Sharma, A. Swing, Y. Li, C. Liu, C. G. Bostock, Y. Bansal, Z. Nado, A. Anand, J. Lipschultz, A. Karmarkar, L. Proleev, A. Ittycheriah, S. H. Yeganeh, G. Polovets, A. Faust, J. Sun, A. Rrustemi, P. Li, R. Shivanna, J. Liu, C. Welty, F. Lebron, A. Baddepudi, S. Krause, E. Parisotto, R. Soricut, Z. Xu, D. Bloxwich, M. Johnson, B. Neyshabur, J. Mao-Jones, R. Wang, V. Ramasesh, Z. Abbas, A. Guez, C. Segal, D. D. Nguyen, J. Svensson, L. Hou, S. York, K. Milan, S. Bridgers, W. Gworek, M. Tagliasacchi, J. Lee-Thorp, M. Chang, A. Guseynov, A. J. Hartman, M. Kwong, R. Zhao, S. Kashem, E. Cole, A. Miech, R. Tanburn, M. Phuong, F. Pavetic, S. Cevey, R. Comanescu, R. Ives, S. Yang, C. Du, B. Li, Z. Zhang, M. Iinuma, C. H. Hu, A. Roy, S. Bijwadia, Z. Zhu, D. Martins, R. Saputro, A. Gergely, S. Zheng, D. Jia, I. Antonoglou, A. Sadovsky, S. Gu, Y. Bi, A. Andreev, S. Samangooui, M. Khan, T. Kocisky, A. Filos, C. Kumar, C. Bishop, A. Yu, S. Hodkinson, S. Mittal, P. Shah, A. Moufarek, Y. Cheng, A. Bloniarz, J. Lee, P. Pejman, P. Michel, S. Spencer, V. Feinberg, X. Xiong, N. Savinov, C. Smith, S. Shakeri, D. Tran, M. Chesus, B. Bohnet, G. Tucker, T. von Glehn, C. Muir, Y. Mao, H. Kazawa, A. Slone, K. Soparkar, D. Shrivastava, J. Cobon-Kerr, M. Sharman, J. Pavagadhi, C. Araya, K. Misiunas, N. Ghelani, M. Laskin, D. Barker, Q. Li, A. Briukhov, N. Houlsby, M. Glaese, B. Lakshminarayanan, N. Schucher, Y. Tang, E. Collins, H. Lim, F. Feng, A. Recasens, G. Lai, A. Magni, N. D. Cao, A. Siddhant, Z. Ashwood, J. Orbay, M. Dehghani, J. Brennan, Y. He, K. Xu, Y. Gao, C. Saroufim, J. Molloy, X. Wu, S. Arnold, S. Chang, J. Schrittwieser, E. Buchatskaya, S. Radpour, M. Polacek, S. Giordano, A. Bapna, S. Tokumine, V. Hellendoorn, T. Sottiaux, S. Cogan, A. Severyn, M. Saleh, S. Thakoor, L. Shefey, S. Qiao, M. Gaba, S. yiin Chang, C. Swanson, B. Zhang, B. Lee, P. K. Rubenstein, G. Song, T. Kwiatkowski, A. Koop, A. Kannan, D. Kao, P. Schuh, A. Stjerngren, G. Ghiasi, G. Gibson, L. Vilnis, Y. Yuan, F. T. Ferreira, A. Kamath, T. Klimenko, K. Franko, K. Xiao, I. Bhattacharya, M. Patel, R. Wang, A. Morris, R. Strudel, V. Sharma, P. Choy, S. H. Hashemi, J. Landon, M. Finkelstein, P. Jhakra, J. Frye, M. Barnes, M. Mauger, D. Daun, K. Baatarsukh, M. Tung, W. Farhan, H. Michalewski, F. Viola, F. de Chaumont Quित्रy, C. L. Lan, T. Hudson, Q. Wang, F. Fischer, I. Zheng, E. White, A. Dragan, J. baptiste Alayrac, E. Ni, A. Pritzel, A. Iwanicki, M. Isard, A. Bulanova, L. Zilka, E. Dyer, D. Sachan, S. Srinivasan, H. Muckenhirn, H. Cai, A. Mandhane, M. Tariq, J. W. Rae, G. Wang, K. Ayoub, N. FitzGerald, Y. Zhao, W. Han, C. Alberti, D. Garrette, K. Krishnakumar, M. Gimenez, A. Levskaya, D. Sohn, J. Matak, I. Iturrate, M. B. Chang, J. Xiang,

Y. Cao, N. Ranka, G. Brown, A. Hutter, V. Mirrokni, N. Chen, K. Yao, Z. Egyed, F. Galilee, T. Liechty, P. Kallakuri, E. Palmer, S. Ghemawat, J. Liu, D. Tao, C. Thornton, T. Green, M. Jasarevic, S. Lin, V. Cotruta, Y.-X. Tan, N. Fiedel, H. Yu, E. Chi, A. Neitz, J. Heitkaemper, A. Sinha, D. Zhou, Y. Sun, C. Kaed, B. Hulse, S. Mishra, M. Georgaki, S. Kudugunta, C. Farabet, I. Shafran, D. Vlasic, A. Tsitsulin, R. Ananthanarayanan, A. Carin, G. Su, P. Sun, S. V, G. Carvajal, J. Broder, I. Comsa, A. Repina, W. Wong, W. W. Chen, P. Hawkins, E. Filonov, L. Loher, C. Hirnschall, W. Wang, J. Ye, A. Burns, H. Cate, D. G. Wright, F. Piccinini, L. Zhang, C.-C. Lin, I. Gog, Y. Kulizhskaya, A. Sreevatsa, S. Song, L. C. Cobo, A. Iyer, C. Tekur, G. Garrido, Z. Xiao, R. Kemp, H. S. Zheng, H. Li, A. Agarwal, C. Ngani, K. Goshvadi, R. Santamaria-Fernandez, W. Fica, X. Chen, C. Gorgolewski, S. Sun, R. Garg, X. Ye, S. M. A. Eslami, N. Hua, J. Simon, P. Joshi, Y. Kim, I. Tenney, S. Potluri, L. N. Thiet, Q. Yuan, F. Luisier, A. Chronopoulou, S. Scellato, P. Srinivasan, M. Chen, V. Koverkathu, V. Dalibard, Y. Xu, B. Saeta, K. Anderson, T. Sellam, N. Fernando, F. Huot, J. Jung, M. Varadarajan, M. Quinn, A. Raul, M. Le, R. Habalov, J. Clark, K. Jalan, K. Bullard, A. Singhal, T. Luong, B. Wang, S. Rajayogam, J. Eisenschlos, J. Jia, D. Finchelstein, A. Yakubovich, D. Balle, M. Fink, S. Agarwal, J. Li, D. Dvijotham, S. Pal, K. Kang, J. Konzelmann, J. Beattie, O. Dousse, D. Wu, R. Crocker, C. Elkind, S. R. Jonnalagadda, J. Lee, D. Holtmann-Rice, K. Kallarackal, R. Liu, D. Vnukov, N. Vats, L. Invernizzi, M. Jafari, H. Zhou, L. Taylor, J. Prendki, M. Wu, T. Eccles, T. Liu, K. Kopparapu, F. Beaufays, C. Angermueller, A. Marzoca, S. Sarcar, H. Dib, J. Stanway, F. Perbet, N. Trdin, R. Sterneck, A. Khorlin, D. Li, X. Wu, S. Goenka, D. Madras, S. Goldshtein, W. Gierke, T. Zhou, Y. Liu, Y. Liang, A. White, Y. Li, S. Singh, S. Bahargam, M. Epstein, S. Basu, L. Lao, A. Ozturk, C. Crous, A. Zhai, H. Lu, Z. Tung, N. Gaur, A. Walton, L. Dixon, M. Zhang, A. Globerson, G. Uy, A. Bolt, O. Wiles, M. Nasr, I. Shumailov, M. Selvi, F. Piccinno, R. Aguilar, S. McCarthy, M. Khalman, M. Shukla, V. Galic, J. Carpenter, K. Villela, H. Zhang, H. Richardson, J. Martens, M. Bosnjak, S. R. Belle, J. Seibert, M. Alnahlawi, B. McWilliams, S. Singh, A. Louis, W. Ding, D. Popovici, L. Simicich, L. Knight, P. Mehta, N. Gupta, C. Shi, S. Fatehi, J. Mitrovic, A. Grills, J. Pagadora, T. Munkhdalai, D. Petrova, D. Eisenbud, Z. Zhang, D. Yates, B. Mittal, N. Tripuraneni, Y. Assael, T. Brovelli, P. Jain, M. Velimirovic, C. Akbulut, J. Mu, W. Macherey, R. Kumar, J. Xu, H. Qureshi, G. Comanici, J. Wiesner, Z. Gong, A. Ruddock, M. Bauer, N. Felt, A. GP, A. Arnab, D. Zelle, J. Rothfuss, B. Rosgen, A. Shenoy, B. Seybold, X. Li, J. Mudigonda, G. Erdogan, J. Xia, J. Simsa, A. Michi, Y. Yao, C. Yew, S. Kan, I. Caswell, C. Radebaugh, A. Elisseeff, P. Valenzuela, K. McKinney, K. Paterson, A. Cui, E. Latorre-Chimoto, S. Kim, W. Zeng, K. Durden, P. Ponnappalli, T. Sosea, C. A. Choquette-Choo, J. Manyika, B. Robenek, H. Vashisht, S. Pereira, H. Lam, M. Velic, D. Owusu-Afriyie, K. Lee, T. Bolukbasi, A. Parrish, S. Lu, J. Park,

- B. Venkatraman, A. Talbert, L. Rosique, Y. Cheng, A. Sozanschi, A. Paszke, P. Kumar, J. Austin, L. Li, K. Salama, B. Perz, W. Kim, N. Dukkupati, A. Baryshnikov, C. Kaplanis, X. Sheng, Y. Chervonyi, C. Unlu, D. de Las Casas, H. Askham, K. Tunyasuvunakool, F. Gimeno, S. Poder, C. Kwak, M. Miecznikowski, V. Mirrokni, A. Dimitriev, A. Parisi, D. Liu, T. Tsai, T. Shevlane, C. Kouridi, D. Garmon, A. Goedeckemeyer, A. R. Brown, A. Vijayakumar, A. Elqursh, S. Jazayeri, J. Huang, S. M. Carthy, J. Hoover, L. Kim, S. Kumar, W. Chen, C. Biles, G. Bingham, E. Rosen, L. Wang, Q. Tan, D. Engel, F. Pongetti, D. de Cesare, D. Hwang, L. Yu, J. Pullman, S. Narayanan, K. Levin, S. Gopal, M. Li, A. Aharoni, T. Trinh, J. Lo, N. Casagrande, R. Vij, L. Matthey, B. Ramadhana, A. Matthews, C. Carey, M. Johnson, K. Goranova, R. Shah, S. Ashraf, K. Dasgupta, R. Larsen, Y. Wang, M. R. Vuyyuru, C. Jiang, J. Ijazi, K. Osawa, C. Smith, R. S. Boppana, T. Bilal, Y. Koizumi, Y. Xu, Y. Altun, N. Shabat, B. Bariach, A. Korchemniy, K. Choo, O. Ronneberger, C. Iwuanyanwu, S. Zhao, D. Soergel, C.-J. Hsieh, I. Cai, S. Iqbal, M. Sundermeyer, Z. Chen, E. Bursztein, C. Malaviya, F. Biadsy, P. Shroff, I. Dhillon, T. Latkar, C. Dyer, H. Forbes, M. Nicosia, V. Nikolaev, S. Greene, M. Georgiev, P. Wang, N. Martin, H. Sedghi, J. Zhang, P. Banzal, D. Fritz, V. Rao, X. Wang, J. Zhang, V. Patraucean, D. Du, I. Mordatch, I. Jurin, L. Liu, A. Dubey, A. Mohan, J. Nowakowski, V.-D. Ion, N. Wei, R. Tojo, M. A. Raad, D. A. Hudson, V. Keshava, S. Agrawal, K. Ramirez, Z. Wu, H. Nguyen, J. Liu, M. Sewak, B. Petrini, D. Choi, I. Philips, Z. Wang, I. Bica, A. Garg, J. Wilkiewicz, P. Agrawal, X. Li, D. Guo, E. Xue, N. Shaik, A. Leach, S. M. Khan, J. Wiesinger, S. Jerome, A. Chakladar, A. W. Wang, T. Ornduff, F. Abu, A. Ghaffarkhah, M. Wainwright, M. Cortes, F. Liu, J. Maynez, A. Terzis, P. Samangouei, R. Mansour, T. Kępa, F.-X. Aubet, A. Algymr, D. Banica, A. Weisz, A. Orban, A. Senges, E. Andrejczuk, M. Geller, N. D. Santo, V. Anklin, M. A. Merrey, M. Baeuml, T. Strohmman, J. Bai, S. Petrov, Y. Wu, D. Hassabis, K. Kavukcuoglu, J. Dean, and O. Vinyals, “Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context,” 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2403.05530>
- [78] OpenAI, :, A. Jaech, A. Kalai, A. Lerer, A. Richardson, A. El-Kishky, A. Low, A. Helyar, A. Madry, A. Beutel, A. Carney, A. Iftimie, A. Karpenko, A. T. Passos, A. Neitz, A. Prokofiev, A. Wei, A. Tam, A. Bennett, A. Kumar, A. Saraiva, A. Vallone, A. Duberstein, A. Kondrich, A. Mishchenko, A. Applebaum, A. Jiang, A. Nair, B. Zoph, B. Ghorbani, B. Rossen, B. Sokolowsky, B. Barak, B. McGrew, B. Minaiev, B. Hao, B. Baker, B. Houghton, B. McKinzie, B. Eastman, C. Lugaresi, C. Bassin, C. Hudson, C. M. Li, C. de Bourcy, C. Voss, C. Shen, C. Zhang, C. Koch, C. Orsinger, C. Hesse, C. Fischer, C. Chan, D. Roberts, D. Kappler, D. Levy, D. Selsam, D. Dohan, D. Farhi, D. Mely, D. Robinson, D. Tsipras, D. Li, D. Oprica, E. Freeman, E. Zhang, E. Wong, E. Proehl, E. Cheung, E. Mitchell, E. Wallace, E. Ritter, E. Mays, F. Wang, F. P. Such,

- F. Raso, F. Leoni, F. Tsimplouras, F. Song, F. von Lohmann, F. Sulit, G. Salmon, G. Parascandolo, G. Chabot, G. Zhao, G. Brockman, G. Leclerc, H. Salman, H. Bao, H. Sheng, H. Andrin, H. Bagherinezhad, H. Ren, H. Lightman, H. W. Chung, I. Kivlichan, I. O'Connell, I. Osband, I. C. Gilaberte, I. Akkaya, I. Kostrikov, I. Sutskever, I. Kofman, J. Pachocki, J. Lennon, J. Wei, J. Harb, J. Twore, J. Feng, J. Yu, J. Weng, J. Tang, J. Yu, J. Q. Candela, J. Palermo, J. Parish, J. Heidecke, J. Hallman, J. Rizzo, J. Gordon, J. Uesato, J. Ward, J. Huizinga, J. Wang, K. Chen, K. Xiao, K. Singhal, K. Nguyen, K. Cobbe, K. Shi, K. Wood, K. Rimbach, K. Gu-Lemberg, K. Liu, K. Lu, K. Stone, K. Yu, L. Ahmad, L. Yang, L. Liu, L. Maksin, L. Ho, L. Fedus, L. Weng, L. Li, L. McCallum, L. Held, L. Kuhn, L. Kondraciuk, L. Kaiser, L. Metz, M. Boyd, M. Trebacz, M. Joglekar, M. Chen, M. Tintor, M. Meyer, M. Jones, M. Kaufer, M. Schwarzer, M. Shah, M. Yatbaz, M. Y. Guan, M. Xu, M. Yan, M. Glaese, M. Chen, M. Lampe, M. Malek, M. Wang, M. Fradin, M. McClay, M. Pavlov, M. Wang, M. Wang, M. Murati, M. Bavarian, M. Rohaninejad, N. McAleese, N. Chowdhury, N. Chowdhury, N. Ryder, N. Tezak, N. Brown, O. Nachum, O. Boiko, O. Murk, O. Watkins, P. Chao, P. Ashbourne, P. Izmailov, P. Zhokhov, R. Dias, R. Arora, R. Lin, R. G. Lopes, R. Gaon, R. Miyara, R. Leike, R. Hwang, R. Garg, R. Brown, R. James, R. Shu, R. Cheu, R. Greene, S. Jain, S. Altman, S. Toizer, S. Toyer, S. Miserendino, S. Agarwal, S. Hernandez, S. Baker, S. McKinney, S. Yan, S. Zhao, S. Hu, S. Santurkar, S. R. Chaudhuri, S. Zhang, S. Fu, S. Papay, S. Lin, S. Balaji, S. Sanjeev, S. Sidor, T. Broda, A. Clark, T. Wang, T. Gordon, T. Sanders, T. Patwardhan, T. Sottiaux, T. Degry, T. Dimson, T. Zheng, T. Garipov, T. Stasi, T. Bansal, T. Creech, T. Peterson, T. Eloundou, V. Qi, V. Kosaraju, V. Monaco, V. Pong, V. Fomenko, W. Zheng, W. Zhou, W. McCabe, W. Zaremba, Y. Dubois, Y. Lu, Y. Chen, Y. Cha, Y. Bai, Y. He, Y. Zhang, Y. Wang, Z. Shao, and Z. Li, "Openai o1 system card," 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2412.16720>
- [79] D. Guo, D. Yang, H. Zhang, J. Song, P. Wang, Q. Zhu, R. Xu, R. Zhang, S. Ma, X. Bi, X. Zhang, X. Yu, Y. Wu, Z. F. Wu, Z. Gou, Z. Shao, Z. Li, Z. Gao, A. Liu, B. Xue, B. Wang, B. Wu, B. Feng, C. Lu, C. Zhao, C. Deng, C. Ruan, D. Dai, D. Chen, D. Ji, E. Li, F. Lin, F. Dai, F. Luo, G. Hao, G. Chen, G. Li, H. Zhang, H. Xu, H. Ding, H. Gao, H. Qu, H. Li, J. Guo, J. Li, J. Chen, J. Yuan, J. Tu, J. Qiu, J. Li, J. L. Cai, J. Ni, J. Liang, J. Chen, K. Dong, K. Hu, K. You, K. Gao, K. Guan, K. Huang, K. Yu, L. Wang, L. Zhang, L. Zhao, L. Wang, L. Zhang, L. Xu, L. Xia, M. Zhang, M. Zhang, M. Tang, M. Zhou, M. Li, M. Wang, M. Li, N. Tian, P. Huang, P. Zhang, Q. Wang, Q. Chen, Q. Du, R. Ge, R. Zhang, R. Pan, R. Wang, R. J. Chen, R. L. Jin, R. Chen, S. Lu, S. Zhou, S. Chen, S. Ye, S. Wang, S. Yu, S. Zhou, S. Pan, S. S. Li, S. Zhou, S. Wu, T. Yun, T. Pei, T. Sun, T. Wang, W. Zeng, W. Liu, W. Liang, W. Gao, W. Yu, W. Zhang, W. L. Xiao, W. An, X. Liu, X. Wang, X. Chen, X. Nie, X. Cheng, X. Liu, X. Xie, X. Liu, X. Yang, X. Li, X. Su, X. Lin, X. Q. Li, X. Jin,

- X. Shen, X. Chen, X. Sun, X. Wang, X. Song, X. Zhou, X. Wang, X. Shan, Y. K. Li, Y. Q. Wang, Y. X. Wei, Y. Zhang, Y. Xu, Y. Li, Y. Zhao, Y. Sun, Y. Wang, Y. Yu, Y. Zhang, Y. Shi, Y. Xiong, Y. He, Y. Piao, Y. Wang, Y. Tan, Y. Ma, Y. Liu, Y. Guo, Y. Ou, Y. Wang, Y. Gong, Y. Zou, Y. He, Y. Xiong, Y. Luo, Y. You, Y. Liu, Y. Zhou, Y. X. Zhu, Y. Huang, Y. Li, Y. Zheng, Y. Zhu, Y. Ma, Y. Tang, Y. Zha, Y. Yan, Z. Z. Ren, Z. Ren, Z. Sha, Z. Fu, Z. Xu, Z. Xie, Z. Zhang, Z. Hao, Z. Ma, Z. Yan, Z. Wu, Z. Gu, Z. Zhu, Z. Liu, Z. Li, Z. Xie, Z. Song, Z. Pan, Z. Huang, Z. Xu, Z. Zhang, and Z. Zhang, “Deepseek-r1 incentivizes reasoning in llms through reinforcement learning,” *Nature*, vol. 645, no. 8081, p. 633–638, Sep. 2025. [En línea]. Disponible en: <http://dx.doi.org/10.1038/s41586-025-09422-z>
- [80] A. Grattafiori, A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Vaughan, A. Yang, A. Fan, A. Goyal, A. Hartshorn, A. Yang, A. Mitra, A. Sravankumar, A. Korenev, A. Hinsvark, A. Rao, A. Zhang, A. Rodriguez, A. Gregerson, A. Spataru, B. Roziere, B. Biron, B. Tang, B. Chern, C. Caucheteux, C. Nayak, C. Bi, C. Marra, C. McConnell, C. Keller, C. Touret, C. Wu, C. Wong, C. C. Ferrer, C. Nikolaidis, D. Allonsius, D. Song, D. Pintz, D. Livshits, D. Wyatt, D. Esiobu, D. Choudhary, D. Mahajan, D. Garcia-Olano, D. Perino, D. Hupkes, E. Lakomkin, E. AlBadawy, E. Lobanova, E. Dinan, E. M. Smith, F. Radenovic, F. Guzmán, F. Zhang, G. Synnaeve, G. Lee, G. L. Anderson, G. Thattai, G. Nail, G. Mialon, G. Pang, G. Cucurell, H. Nguyen, H. Korevaar, H. Xu, H. Touvron, I. Zarov, I. A. Ibarra, I. Kloumann, I. Misra, I. Evtimov, J. Zhang, J. Copet, J. Lee, J. Geffert, J. Vranes, J. Park, J. Mahadeokar, J. Shah, J. van der Linde, J. Billock, J. Hong, J. Lee, J. Fu, J. Chi, J. Huang, J. Liu, J. Wang, J. Yu, J. Bitton, J. Spisak, J. Park, J. Rocca, J. Johnston, J. Saxe, J. Jia, K. V. Alwala, K. Prasad, K. Upasani, K. Plawiak, K. Li, K. Heafield, K. Stone, K. El-Arini, K. Iyer, K. Malik, K. Chiu, K. Bhalla, K. Lakhotia, L. Rantala-Yearly, L. van der Maaten, L. Chen, L. Tan, L. Jenkins, L. Martin, L. Madaan, L. Malo, L. Blecher, L. Landzaat, L. de Oliveira, M. Muzzi, M. Pasupuleti, M. Singh, M. Paluri, M. Kardas, M. Tsimpoukelli, M. Oldham, M. Rita, M. Pavlova, M. Kambadur, M. Lewis, M. Si, M. K. Singh, M. Hassan, N. Goyal, N. Torabi, N. Bashlykov, N. Bogoychev, N. Chatterji, N. Zhang, O. Duchenne, O. Çelebi, P. Alrassy, P. Zhang, P. Li, P. Vasic, P. Weng, P. Bhargava, P. Dubal, P. Krishnan, P. S. Koura, P. Xu, Q. He, Q. Dong, R. Srinivasan, R. Ganapathy, R. Calderer, R. S. Cabral, R. Stojnic, R. Raileanu, R. Maheswari, R. Girdhar, R. Patel, R. Sauvestre, R. Polidoro, R. Sumbaly, R. Taylor, R. Silva, R. Hou, R. Wang, S. Hosseini, S. Chennabasappa, S. Singh, S. Bell, S. S. Kim, S. Edunov, S. Nie, S. Narang, S. Raparthy, S. Shen, S. Wan, S. Bhosale, S. Zhang, S. Vandenhennde, S. Batra, S. Whitman, S. Sootla, S. Collot, S. Gururangan, S. Borodinsky, T. Herman, T. Fowler, T. Sheasha, T. Georgiou, T. Scialom, T. Speckbacher, T. Mihaylov, T. Xiao, U. Karn, V. Goswami, V. Gupta, V. Ramanathan, V. Kerkez, V. Gonguet, V. Do, V. Vogeti, V. Albiero, V. Petrovic, W. Chu, W. Xiong, W. Fu,

W. Meers, X. Martinet, X. Wang, X. Wang, X. E. Tan, X. Xia, X. Xie, X. Jia, X. Wang, Y. Goldschlag, Y. Gaur, Y. Babaei, Y. Wen, Y. Song, Y. Zhang, Y. Li, Y. Mao, Z. D. Coudert, Z. Yan, Z. Chen, Z. Papakipos, A. Singh, A. Srivastava, A. Jain, A. Kelsey, A. Shajnfeld, A. Gangidi, A. Victoria, A. Goldstand, A. Menon, A. Sharma, A. Boesenberg, A. Baevski, A. Feinstein, A. Kallet, A. Sangani, A. Teo, A. Yunus, A. Lupu, A. Alvarado, A. Caples, A. Gu, A. Ho, A. Poulton, A. Ryan, A. Ramchandani, A. Dong, A. Franco, A. Goyal, A. Saraf, A. Chowdhury, A. Gabriel, A. Bharambe, A. Eisenman, A. Yazdan, B. James, B. Maurer, B. Leonhardi, B. Huang, B. Loyd, B. D. Paola, B. Paranjape, B. Liu, B. Wu, B. Ni, B. Hancock, B. Wasti, B. Spence, B. Stojkovic, B. Gamido, B. Montalvo, C. Parker, C. Burton, C. Mejia, C. Liu, C. Wang, C. Kim, C. Zhou, C. Hu, C.-H. Chu, C. Cai, C. Tindal, C. Feichtenhofer, C. Gao, D. Civin, D. Beaty, D. Kreymer, D. Li, D. Adkins, D. Xu, D. Testuggine, D. David, D. Parikh, D. Liskovich, D. Foss, D. Wang, D. Le, D. Holland, E. Dowling, E. Jamil, E. Montgomery, E. Presani, E. Hahn, E. Wood, E.-T. Le, E. Brinkman, E. Arcaute, E. Dunbar, E. Smothers, F. Sun, F. Kreuk, F. Tian, F. Kokkinos, F. Ozgenel, F. Caggioni, F. Kanayet, F. Seide, G. M. Florez, G. Schwarz, G. Badeer, G. Swee, G. Halpern, G. Herman, G. Sizov, Guangyi, Zhang, G. Lakshminarayanan, H. Inan, H. Shojanazeri, H. Zou, H. Wang, H. Zha, H. Habeeb, H. Rudolph, H. Suk, H. Aspegren, H. Goldman, H. Zhan, I. Damla, I. Molybog, I. Tufanov, I. Leontiadis, I.-E. Veliche, I. Gat, J. Weissman, J. Geboski, J. Kohli, J. Lam, J. Asher, J.-B. Gaya, J. Marcus, J. Tang, J. Chan, J. Zhen, J. Reizenstein, J. Teboul, J. Zhong, J. Jin, J. Yang, J. Cummings, J. Carvill, J. Shepard, J. McPhie, J. Torres, J. Ginsburg, J. Wang, K. Wu, K. H. U, K. Saxena, K. Khandelwal, K. Zand, K. Matosich, K. Veeraraghavan, K. Michelena, K. Li, K. Jagadeesh, K. Huang, K. Chawla, K. Huang, L. Chen, L. Garg, L. A, L. Silva, L. Bell, L. Zhang, L. Guo, L. Yu, L. Moshkovich, L. Wehrstedt, M. Khabsa, M. Avalani, M. Bhatt, M. Mankus, M. Hasson, M. Lennie, M. Reso, M. Groshev, M. Naumov, M. Lathi, M. Keneally, M. Liu, M. L. Seltzer, M. Valko, M. Restrepo, M. Patel, M. Vyatskov, M. Samvelyan, M. Clark, M. Macey, M. Wang, M. J. Hermoso, M. Metanat, M. Rastegari, M. Bansal, N. Santhanam, N. Parks, N. White, N. Bawa, N. Singhal, N. Egebo, N. Usunier, N. Mehta, N. P. Laptev, N. Dong, N. Cheng, O. Chernoguz, O. Hart, O. Salpekar, O. Kalinli, P. Kent, P. Parekh, P. Saab, P. Balaji, P. Rittner, P. Bontrager, P. Roux, P. Dollar, P. Zvyagina, P. Ratanchandani, P. Yuvraj, Q. Liang, R. Alao, R. Rodriguez, R. Ayub, R. Murthy, R. Nayani, R. Mitra, R. Parthasarathy, R. Li, R. Hogan, R. Battey, R. Wang, R. Howes, R. Rinott, S. Mehta, S. Siby, S. J. Bondu, S. Datta, S. Chugh, S. Hunt, S. Dhillon, S. Sidorov, S. Pan, S. Mahajan, S. Verma, S. Yamamoto, S. Ramaswamy, S. Lindsay, S. Lindsay, S. Feng, S. Lin, S. C. Zha, S. Patil, S. Shankar, S. Zhang, S. Zhang, S. Wang, S. Agarwal, S. Sajuyigbe, S. Chintala, S. Max, S. Chen, S. Kehoe, S. Satterfield, S. Govindaprasad, S. Gupta, S. Deng, S. Cho, S. Virk, S. Subramanian, S. Choudhury,

- S. Goldman, T. Remez, T. Glaser, T. Best, T. Koehler, T. Robinson, T. Li, T. Zhang, T. Matthews, T. Chou, T. Shaked, V. Vontimitta, V. Ajayi, V. Montanez, V. Mohan, V. S. Kumar, V. Mangla, V. Ionescu, V. Poenaru, V. T. Mihailescu, V. Ivanov, W. Li, W. Wang, W. Jiang, W. Bouaziz, W. Constable, X. Tang, X. Wu, X. Wang, X. Wu, X. Gao, Y. Kleinman, Y. Chen, Y. Hu, Y. Jia, Y. Qi, Y. Li, Y. Zhang, Y. Zhang, Y. Adi, Y. Nam, Yu, Wang, Y. Zhao, Y. Hao, Y. Qian, Y. Li, Y. He, Z. Rait, Z. DeVito, Z. Rosnbrick, Z. Wen, Z. Yang, Z. Zhao, and Z. Ma, “The llama 3 herd of models,” 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2407.21783>
- [81] T. GLM, :, A. Zeng, B. Xu, B. Wang, C. Zhang, D. Yin, D. Zhang, D. Rojas, G. Feng, H. Zhao, H. Lai, H. Yu, H. Wang, J. Sun, J. Zhang, J. Cheng, J. Gui, J. Tang, J. Zhang, J. Sun, J. Li, L. Zhao, L. Wu, L. Zhong, M. Liu, M. Huang, P. Zhang, Q. Zheng, R. Lu, S. Duan, S. Zhang, S. Cao, S. Yang, W. L. Tam, W. Zhao, X. Liu, X. Xia, X. Zhang, X. Gu, X. Lv, X. Liu, X. Liu, X. Yang, X. Song, X. Zhang, Y. An, Y. Xu, Y. Niu, Y. Yang, Y. Li, Y. Bai, Y. Dong, Z. Qi, Z. Wang, Z. Yang, Z. Du, Z. Hou, and Z. Wang, “Chatglm: A family of large language models from glm-130b to glm-4 all tools,” 2024. [En línea]. Disponible en: <https://arxiv.org/abs/2406.12793>
- [82] G. Team, A. Kamath, J. Ferret, S. Pathak, N. Vieillard, R. Merhej, S. Perrin, T. Matejovicova, A. Ramé, M. Rivière, L. Rouillard, T. Mesnard, G. Cideron, J. bastien Grill, S. Ramos, E. Yvinec, M. Casbon, E. Pot, I. Penchev, G. Liu, F. Visin, K. Kenealy, L. Beyer, X. Zhai, A. Tsitsulin, R. Busa-Fekete, A. Feng, N. Sachdeva, B. Coleman, Y. Gao, B. Mustafa, I. Barr, E. Parisotto, D. Tian, M. Eyal, C. Cherry, J.-T. Peter, D. Sinopalnikov, S. Bhupatiraju, R. Agarwal, M. Kazemi, D. Malkin, R. Kumar, D. Vilar, I. Brusilovsky, J. Luo, A. Steiner, A. Friesen, A. Sharma, A. Sharma, A. M. Gilady, A. Goedeckemeyer, A. Saade, A. Feng, A. Kolesnikov, A. Bendebury, A. Abdagic, A. Vadi, A. György, A. S. Pinto, A. Das, A. Bapna, A. Miech, A. Yang, A. Paterson, A. Shenoy, A. Chakrabarti, B. Piot, B. Wu, B. Shahriari, B. Petrini, C. Chen, C. L. Lan, C. A. Choquette-Choo, C. Carey, C. Brick, D. Deutsch, D. Eisenbud, D. Cattle, D. Cheng, D. Paparas, D. S. Sreepathihalli, D. Reid, D. Tran, D. Zelle, E. Noland, E. Huizenga, E. Kharitonov, F. Liu, G. Amirkhanyan, G. Cameron, H. Hashemi, H. Klimczak-Plucińska, H. Singh, H. Mehta, H. T. Lehri, H. Hazimeh, I. Ballantyne, I. Szpektor, I. Nardini, J. Pouget-Abadie, J. Chan, J. Stanton, J. Wieting, J. Lai, J. Orbay, J. Fernandez, J. Newlan, J. yeong Ji, J. Singh, K. Black, K. Yu, K. Hui, K. Vodrahalli, K. Greff, L. Qiu, M. Valentine, M. Coelho, M. Ritter, M. Hoffman, M. Watson, M. Chaturvedi, M. Moynihan, M. Ma, N. Babar, N. Noy, N. Byrd, N. Roy, N. Momchev, N. Chauhan, N. Sachdeva, O. Bunyan, P. Botarda, P. Caron, P. K. Rubenstein, P. Culliton, P. Schmid, P. G. Sessa, P. Xu, P. Stanczyk, P. Tafti, R. Shivanna, R. Wu, R. Pan, R. Rokni, R. Willoughby, R. Vallu, R. Mullins, S. Jerome, S. Smoot,

- S. Girgin, S. Iqbal, S. Reddy, S. Sheth, S. Pöder, S. Bhatnagar, S. R. Panyam, S. Eiger, S. Zhang, T. Liu, T. Yacovone, T. Liechty, U. Kalra, U. Evci, V. Misra, V. Roseberry, V. Feinberg, V. Kolesnikov, W. Han, W. Kwon, X. Chen, Y. Chow, Y. Zhu, Z. Wei, Z. Egyed, V. Cotruta, M. Giang, P. Kirk, A. Rao, K. Black, N. Babar, J. Lo, E. Moreira, L. G. Martins, O. Sanseviero, L. Gonzalez, Z. Gleicher, T. Warkentin, V. Mirrokni, E. Senter, E. Collins, J. Barral, Z. Ghahramani, R. Hadsell, Y. Matias, D. Sculley, S. Petrov, N. Fiedel, N. Shazeer, O. Vinyals, J. Dean, D. Hassabis, K. Kavukcuoglu, C. Farabet, E. Buchatskaya, J.-B. Alayrac, R. Anil, Dmitry, Lepikhin, S. Borgeaud, O. Bachem, A. Joulin, A. Andreev, C. Hardin, R. Dadashi, and L. Hussenot, “Gemma 3 technical report,” 2025. [En línea]. Disponible en: <https://arxiv.org/abs/2503.19786>
- [83] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, C. Zheng, D. Liu, F. Zhou, F. Huang, F. Hu, H. Ge, H. Wei, H. Lin, J. Tang, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Zhou, J. Lin, K. Dang, K. Bao, K. Yang, L. Yu, L. Deng, M. Li, M. Xue, M. Li, P. Zhang, P. Wang, Q. Zhu, R. Men, R. Gao, S. Liu, S. Luo, T. Li, T. Tang, W. Yin, X. Ren, X. Wang, X. Zhang, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Zhang, Y. Wan, Y. Liu, Z. Wang, Z. Cui, Z. Zhang, Z. Zhou, and Z. Qiu, “Qwen3 technical report,” 2025. [En línea]. Disponible en: <https://arxiv.org/abs/2505.09388>
- [84] X. Yao, Y.-B. Kang, and A. McCosker, “Missing the human touch?: A computational stylometric analysis of gpt-4 translations of online chinese literature,” *Translation Spaces*, vol. 14, no. 2, p. 303–330, Nov. 2025. [En línea]. Disponible en: <http://dx.doi.org/10.1075/ts.24043.yao>
- [85] S. Zhu, M. Cui, and D. Xiong, “Towards robust in-context learning for machine translation with large language models,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, N. Calzolari, M.-Y. Kan, V. Hoste, A. Lenci, S. Sakti, and N. Xue, Eds. Torino, Italia: ELRA and ICCL, May 2024, pp. 16 619–16 629. [En línea]. Disponible en: <https://aclanthology.org/2024.lrec-main.1444/>
- [86] X. Garcia, Y. Bansal, C. Cherry, G. Foster, M. Krikun, F. Feng, M. Johnson, and O. Firat, “The unreasonable effectiveness of few-shot learning for machine translation,” 2023. [En línea]. Disponible en: <https://arxiv.org/abs/2302.01398>
- [87] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “Lora: Low-rank adaptation of large language models,” 2021. [En línea]. Disponible en: <https://arxiv.org/abs/2106.09685>